

哈尔滨工业大学硕士学位论文课题 结题报告

行为先验与大语言模型融合的城市旅游行程规划方法研究

张钧瑞 学号：25S112072 数学学院 导师：田波平

2027 年 6 月

目录

1	研究目标与任务完成情况概述	2
2	主要研究成果	2
2.1	实证发现：目的地内旅游转移距离的双峰性	2
2.2	方法成果：先验 $\times$ LLM 融合及其架构必要性论证	2
2.3	两项如实报告的负结果	3
2.4	评测方法学：三层统计评测体系	3
3	实验数据的客观分析	3
3.1	支撑结论的证据强度	3
3.2	局限与不确定因素（辩证）	4
3.3	方法合理性的辩证阐述	4
4	成果清单	5
5	后续工作展望	5
6	主要参考文献	5

1 研究目标与任务完成情况概述

本课题以 168 条真实游记路线（1,660 次相邻转移，全程隔离于训练之外）为行为学金标准，围绕“行为统计建模—先验与 LLM 融合—统计评测体系—系统验证”四项任务展开。开题设定的研究内容与预期目标全部完成，其中两项超额（架构必要性消融、概率校准实验），并按预注册的负结果预案如实报告了两项阴性结果。任务对照见表 1。

表 1: 研究任务完成情况对照

开题任务	完成情况
双峰转移行为的混合建模与检验	完成: dip test $p < 10^{-4}$; lognormal+log-gamma 混合 EM 估计
距离衰减函数族选型	完成: 条件 logit 选型, 混合形式胜出, 纯指数被否决
先验 $\times$ LLM 融合方法与检验	完成: 测试份 43.3% vs 规则 32.3% ($p \approx 0$)
三层统计评测体系	完成: 两层无模型裁决 + 一层描述性似然, 生成层验证
系统接入与演示	完成: 规划器新增先验/融合选择器, 60 指令端到端实验
(超额) 架构必要性消融	完成: 组件去除检验, 部署架构精简为四组件
(超额) LLM 概率校准	完成: 负结果, 校准非本任务瓶颈

2 主要研究成果

2.1 实证发现：目的地内旅游转移距离的双峰性

对全部 1,660 次真实转移的四层检验 [10, 12]: Hartigan dip test 在原始与对数尺度均拒绝单峰 ($p < 10^{-4}$); 路线级自助 100/100 次拒绝; 参数自助似然比检验不支持两分量对数正态 ($p = 0.219$), 表明跨区分量尾部重于对数正态; 最终以 lognormal (中位 0.58km) 与 log-gamma (中位约 25km) 混合刻画, 就近分量权重 0.45。据文献调研, 目的地内粒度的转移距离双峰性正式检验此前未见报道。该发现是融合架构的直接动机: 就近与跨区两种决策模式对应统计先验与语义模型的天然分工。

2.2 方法成果：先验 $\times$ LLM 融合及其架构必要性论证

行为先验 = 二阶区域转移 (8 区域、Dirichlet 平滑) $\times$ 混合距离衰减 $\times$ 一阶类型转移。LLM 侧为 Qwen3.5-4B 微调适配器的候选编号首 token 概率 (单次前向、确定性)。融合采用对数线性池化 [9]: $\log P_{\text{final}} = \lambda \log P_{\text{prior}} + (1 - \lambda) \log P_{\text{llm}}$ 。

测试份 372 点 8 选 1 (配对精确 McNemar[11], Wilson 区间): 随机 13.2%、就近规则 32.3%、LLM 单独 26.6%、先验单独 37.1% ($p = 10^{-4}$)、固定权重融合 43.3% ($p \approx 0$)。核心结论: **LLM 单独弱于规则、融合后显著反超全部基线**——其价值不在绝对精度而在与空间统计的误差互补。

组件消融给出部署架构的最简形式: 距离衰减不可去 (18.8%); 区域项 +4.8 个百分点; 8 区域粒度 +4 个百分点; 平滑常数不敏感; 二阶与一阶命中率持平 (二阶似然更优, 零成本保留)。衰减形式在融合层差异显著 (混合 43.3% 对退化指数 34.4%), 纯指数形式的极大似然尺度参数趋于无穷, 数据不支持。

2.3 两项如实报告的负结果

(1) 状态依赖权重 $\lambda(s)$ (8 维推理时特征、逻辑回归堆叠、嵌套交叉验证) 不优于固定权重 ($p = 1.0$), 学得权重塌缩为 $[0.52, 0.57]$ 窄带——融合增益来自误差互补结构, 而非可学习的状态调度信号; (2) LLM 概率温度校准无测试集增益 (原始期望校准误差仅 0.041, 8 选 1 任务上并非文献所述严重过度自信)。两者共同界定了方法的能力边界, 也构成”融合框架对超参稳健”的证据。

2.4 评测方法学: 三层统计评测体系

以构念效度理论 [15] 区分”行为符合度” (本体系裁决对象) 与”工程质量” (降为附录描述)。三层结构: 点层 (命中率 + 配对 McNemar + Holm 校正, 无模型, 主裁决); 个体层 (路线行为似然 + 配对 Wilcoxon, 模型依赖, 描述性); 群体层 (转移距离与类型节奏的 KS/Wasserstein + 路线级自助 CI, 无模型, 群体裁决)。分层思想借鉴生成模型评测中似然与样本分布判据不可互替的论证 [16]。该体系是对旧综合评分与就近基线同源 (同源权重约占质量分 45%)、聚合掩盖分层结构、训练测试过拟合三类已实证缺陷的方法学回应。

生成层验证 (60 指令 $\times$ 5 选择器): 个体层先验/融合显著高于就近规则 (配对 Wilcoxon $p \approx 0$); 群体层融合 KS 最优 (0.219, bootstrap CI $[0.210, 0.248]$); 真实对真实基线 0.046); 合理性自检通过 (真实路线似然高于全部生成方法)。

3 实验数据的客观分析

3.1 支撑结论的证据强度

主结论 (融合显著优于规则) 在四类独立证据下方向一致: 点层 9.3 个百分点差距 ($p \approx 0$, 功效足够); 个体层似然差 0.50 nat/ 转移 ($p \approx 0$); 群体层分布距离最优; 已

知有偏的旧工程指标下仍胜出。多重证据交叉使结论不依赖任何单一指标的构念。

3.2 局限与不确定因素（辩证）

1. **干扰项构造依赖**：8 选 1 的干扰项由检索池构造，命中率绝对值不可跨研究比较；本课题所有方法共用同一协议，方法间比较不受影响，但外推需谨慎。
2. **循环论证边界**：个体层与融合方法共用行为统计，已通过三层互证（裁决仅依赖无模型层）控制，但个体层数值不进入结论句。
3. **重尾压缩**：全部生成方法的转移距离 90 分位约 5km，真实约 8km 且含 195km 极值——候选池以当前中心检索限制了空间覆盖。就近规则的跨区占比虽形式上接近真实（0.50 对 0.49），但其分布形态差异（KS 0.253）说明比例匹配不等于分布匹配，这本身是聚合指标局限的例证。
4. **粒度不对齐**：群体层参照为整条游记路线而生成单位为日路线，绝对 KS 因此偏大；方法间排序在同协议下有效。
5. **样本上限**：168 条路线约束了细分检验的功效，次级结论（如节奏分项差异）未做多重比较校正的全量声明。
6. **构念边界**：本体系裁决“行为符合度”而非“游客满意度”；生成更接近真实人群统计的路线是否更令具体用户满意，属另一构念，需独立效标（如在线实验）检验，本课题未声称。

3.3 方法合理性的辩证阐述

有利面：行为先验可解释、小样本可估、参数有明确语义；LLM 分量贡献语义与跨区意图；对数池化保持归一性与权重语义；架构经消融精简为四组件，无冗余结构。文献对话上，本框架回答的是“如何可信组合”而非“LLM 能否单独胜任”，与 next-POI 推荐三代方法 [1, 2, 3, 4, 5, 6] 及 LLM 推荐研究 [7, 8] 形成互补而非重复。

约束面：先验的表达上限受区域化粒度约束（更细粒度受稀疏性限制）；LLM 分量的边界依赖基座能力与候选呈现方式；固定权重的全局性是“塌缩实证”支持下的妥协而非理论最优；双峰混合的分量解释（就近/跨区）是统计语义而非行为决策机制的直接观测。

4 成果清单

1. 统计模型与代码：行为先验模型、融合管线、三层评测体系、架构消融、校准实验（全部版本化可复现，含 11 个实验结果数据文件）；
2. 系统成果：行程规划器新增先验/融合选择器并完成 60 指令端到端验证；
3. 数据资产：168 条真实路线的行为学金标准协议（三分索引、功效分析）；
4. 学术成果：学位论文一篇（另呈）；拟投稿论文一篇（融合价值反转 + 评测方法学主线）。

5 后续工作展望

（1）候选检索的全城覆盖实验以缓解重尾压缩；（2）在线 A/B 或专家评分为”满意度”构念建立独立效标；（3）扩展城市验证框架的可迁移性；（4）将三层评测体系整理为开源评测工具。

6 主要参考文献

参考文献

- [1] Rendle S, Freudenthaler C, Schmidt-Thieme L. Factorizing personalized Markov chains for next-basket recommendation. *WWW*, 2010: 811–820.
- [2] Cheng C, Yang H, Lyu M R, King I. Where you like to go next: successive point-of-interest recommendation. *IJCAI*, 2013: 2605–2611.
- [3] Feng S, Li X, Zeng Y, et al. Personalized ranking metric embedding for next new POI recommendation. *IJCAI*, 2015: 2069–2075.
- [4] Liu Q, Wu S, Wang L, Tan T. Predicting the next location: a recurrent model with spatial and temporal contexts. *AAAI*, 2016: 194–200.
- [5] Liu Q, Wu S, Wang L, Tan T. An attentional recurrent neural network for personalized next POI recommendation. *AAAI*, 2019: 83–90.
- [6] Li X, et al. Personalized long- and short-term preference learning for next POI recommendation. *IEEE TKDE*, 2022, 34(4): 1809–1822.
- [7] Li P, de Rijke M, Xue H, et al. Large language models for next point-of-interest recommendation. *SIGIR*, 2024: 1393–1403.

- [8] Wu L, Zheng Z, Qiu Z, et al. A survey on large language models for recommendation. *World Wide Web*, 2024, 27(5): 60.
- [9] Hinton G E. Training products of experts by minimizing contrastive divergence. *Neural Computation*, 2002, 14(8): 1771–1800.
- [10] Hartigan J A, Hartigan P M. The dip test of unimodality. *The Annals of Statistics*, 1985, 13(1): 70–84.
- [11] McNemar Q. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 1947, 12(2): 153–157.
- [12] Efron B, Tibshirani R J. *An Introduction to the Bootstrap*. Chapman & Hall/CRC, 1993.
- [13] Dempster A P, Laird N M, Rubin D B. Maximum likelihood from incomplete data via the EM algorithm. *JRSS-B*, 1977, 39(1): 1–22.
- [14] Guo C, Pleiss G, Sun Y, Weinberger K Q. On calibration of modern neural networks. *ICML*, 2017: 1321–1330.
- [15] Cronbach L J, Meehl P E. Construct validity in psychological tests. *Psychological Bulletin*, 1955, 52(4): 281–302.
- [16] Theis L, van den Oord A, Bethge M. A note on the evaluation of generative models. *ICLR*, 2016.
- [17] Chen Y. The distance-decay function of geographical gravity model: power law or exponential law? *Chaos, Solitons & Fractals*, 2015, 77: 174–189.
- [18] González M C, Hidalgo C A, Barabási A-L. Understanding individual human mobility patterns. *Nature*, 2008, 453: 779–782.
- [19] Simini F, González M C, Maritan A, Barabási A-L. A universal model for mobility and migration patterns. *Nature*, 2012, 484: 96–100.
- [20] McKercher B, Lew A A. Distance decay and the impact of effective tourism exclusion zones on international travel flows. *Journal of Travel Research*, 2003, 42(2): 119–130.
- [21] Mao A, Mohri M, Zhong Y. Learning to defer to multiple experts: consistent surrogate losses. *AISTATS*, 2023.
- [22] Wan F, Wan X. FuseLLM: Knowledge fusion of large language models. *ICLR*, 2024.
- [23] Ong I, Almahairi A, Wu V, et al. RouteLLM: Learning to route LLMs with preference data. *arXiv:2406.18665*, 2024.
- [24] Deng B, Feng Y, Liu Z, et al. RETAIL: Towards real-world travel planning for large language models. *arXiv:2508.15335*, 2025.
- [25] Google Research. Optimizing LLM-based trip planning. Google Research Blog, 2025.