

哈尔滨工业大学

## 硕士学位论文中期报告

题目：行为先验与大语言模型融合的城市旅游行程规划方法研究

院（系） 【学院名称】

学 【学科专业，如：应用统计/计算机科学与技术】

导 师 【导师姓名及职称】

研 究 生 【姓名】

学 号 【学号】

中期报告日期 2026 年 8 月

研究生院制

# 目 录

|                                 |   |
|---------------------------------|---|
| 1 论文工作是否按开题报告预定的内容及进度安排进行 ..... | 1 |
| 2 目前已完成的研究工作及结果 .....           | 1 |
| 2.1 行为统计建模（对应研究内容 1） .....      | 1 |
| 2.2 融合方法与架构必要性（对应研究内容 2） .....  | 1 |
| 2.3 三层统计评测体系（对应研究内容 3） .....    | 2 |
| 2.4 系统接入（对应研究内容 4） .....        | 2 |
| 3 后期拟完成的研究工作及进度安排 .....         | 3 |
| 4 存在的困难与问题 .....                | 3 |
| 5 如期完成全部论文工作的可能性 .....          | 3 |

## 1 论文工作是否按开题报告预定的内容及进度安排进行

论文工作总体按开题报告预定的内容与进度推进，无方向性调整。开题设定的四项研究内容中：（1）目的地内转移行为统计建模已完成主体，处于参数区间估计补充阶段；（2）融合方法研究超额完成，新增了开题未明确列出的组件必要性消融与概率校准实验；（3）三层统计评测体系已从设计文档落地为可复现实验代码并完成生成层验证；（4）系统接入完成（规划器新增先验与融合两档选择器），端到端演示待论文收尾阶段完善。进度上，开题安排的“2026.09–10 完成混合模型参数区间估计与生成层扩展”中，生成层实验已提前完成，参数区间估计顺延至中期检查后，总体进度正常略超前。

## 2 目前已完成的研究工作及结果

### 2.1 行为统计建模（对应研究内容 1）

以拟合份 84 条真实路线估计全部行为模型组件，测试份 42 条仅用于最终评估。主要结果：

1. **双峰性检验：**Hartigan dip test<sup>[1]</sup> 在原始与对数尺度均拒绝单峰（ $p < 10^{-4}$ ）；路线级自助 100/100 次拒绝<sup>[2]</sup>。两分量对数正态混合未获似然比支持（ $p = 0.219$ ），提示跨区分量重于对数正态，最终采用 lognormal（中位 0.58km）与 log-gamma（中位约 25km）的异质混合，EM 估计<sup>[3]</sup>，就近分量权重 0.45。
2. **转移阶数：**参数自助法似然比检验支持二阶区域转移（ $p = 0.005$ ）；样本外对数损失二阶 0.62 对一阶 0.75 nat/转移。需要如实说明：在 top-1 命中率上二阶与一阶持平（37.1% 对 36.8%，配对 McNemar  $p = 1.0$ ），二阶的优势体现在似然质量而非命中率。
3. **距离衰减选型：**候选池离散选择任务上的条件 logit 拟合，混合形式优于幂律与指数（确认份对数损失 1.88 对 2.08/2.09）；纯指数形式的极大似然估计退化为近平坦（尺度参数趋于上界），工程常用的固定指数衰减被数据否决。
4. **区域粒度：**转移计数覆盖分析确定 8 区域（更粗粒度命中率下降约 4 个百分点）。

### 2.2 融合方法与架构必要性（对应研究内容 2）

测试份 372 个预测点、8 选 1 任务，配对精确 McNemar<sup>[4]</sup>：

1. **主结果：**统计先验单独命中率 37.1%，显著高于最强规则基线（就近贪心）的 32.3%（ $p = 10^{-4}$ ）；与 LLM 候选概率对数池化后 43.3%（对规则  $p \approx 0$ ，对

先验单独  $p = 0.005$ )。LLM 单独仅 26.6%——其边际价值在融合框架下实现反转。

2. 架构必要性消融：距离衰减是命脉（去除后降至 18.8%）；区域项贡献 4.8 个百分点；区域数从 8 降到 4/6 损失 4 个百分点；平滑常数在 0.05–0.5 内不敏感。衰减形式对先验单独影响小，但对融合影响大（混合形式 43.3% 对退化的指数形式 34.4%）。
3. 负结果（如实报告）：状态依赖权重  $\lambda(s)$ （逻辑回归堆叠 + 嵌套交叉验证）不优于固定权重（43.0% 对 43.3%， $p = 1.0$ ），学得权重塌缩为  $[0.52, 0.57]$  窄带；LLM 概率温度校准在测试集无实质增益（期望校准误差原始仅 0.041，本任务非严重过度自信）。最终部署架构据此精简为四组件：二阶区域转移、混合距离衰减、LLM 首 token 候选概率、固定权重的对数池化。

### 2.3 三层统计评测体系（对应研究内容 3）

按构念效度框架<sup>[5]</sup>将评测构念明确为“行为符合度”，与“工程质量”分离；三层中两层不依赖任何模型（裁决层），一层依赖行为模型设定（描述性层），三层互证控制循环论证——该分层借鉴生成模型评测中似然与样本分布判据不可互替的论证<sup>[6]</sup>。生成层实验（60 条指令、5 种选择器）：

1. 个体层（描述性）：路线行为对数似然（nat/转移），真实测试路线参照 -3.84 为最高（合理性自检通过）；先验选择器 -4.02、融合 -4.14、就近规则 -4.59、LLM -4.79。配对 Wilcoxon：先验与融合均显著高于就近规则（ $p \approx 0$ ）。
2. 群体层（裁决）：转移距离分布对真实参照的 KS 距离：融合 0.219（最优，bootstrap 95%CI  $[0.210, 0.248]$ ）< 先验 0.248 < 就近 0.253 < LLM 0.270 < 检索序 0.300；真实对真实参照基线为 0.046。跨区占比（真实 0.49）：就近规则 0.50 形式上最接近，但其分布 90 分位 4.4km 相对真实约 8km 存在系统性的重尾压缩——这是全部生成方法的共同局限（源于候选池以当前中心检索），论文将如实报告并列为改进方向。
3. 旧工程指标（附录，描述性）：在已知偏向就近基线的综合评分下，先验（0.78）与融合（0.75）仍高于就近规则（0.65）与 LLM（0.65），结论跨指标族稳健。

### 2.4 系统接入（对应研究内容 4）

行程规划器新增“先验”与“融合”两档候选选择器，逐日生成时逐步以对数转移概率、距离衰减与类型转移打分（融合档再与 LLM 首 token 概率池化，单次前向、确定性）。全部实验脚本与结果数据已版本化，可复现。

### 3 后期拟完成的研究工作及进度安排

1. 2027.01: 混合模型参数区间估计与分量数选择的稳健性补充; 生成层实验的多种子复验。
2. 2027.02: 任务适配微调敏感性实验 (以融合增益为裁决指标, 回应“LLM 基线可能被削弱”的质疑); 多重比较校正 (Holm) 固化到全部报告。
3. 2027.03: Web 演示系统集成与案例分析; 全部消融链复跑。
4. 2027.03–2027.05: 论文撰写、预答辩、修改与正式答辩。

### 4 存在的困难与问题

1. 样本量上限: 真实路线 168 条, 更细的分层检验功效不足, 目前依靠功效前置设计与路线级自助缓解;
2. 重尾压缩: 生成路线缺失真实数据中的极端长转移, 需改进候选检索的空间覆盖 (拟在中期后实验全城候选池方案);
3. 时间风险: 论文撰写与实验收尾并行, 需严格控制微调敏感性实验的规模 (单卡算力约束)。

### 5 如期完成全部论文工作的可能性

核心建模、主实验与评测体系均已完成且结果显著, 剩余工作为稳健性补充、单一敏感性实验、系统集成与论文撰写, 无方向性风险。评估可以如期完成全部论文工作。

- [1] Hartigan J A, Hartigan P M. The Dip Test of Unimodality[J]. The Annals of Statistics, 1985, 13(1): 70-84.
- [2] Efron B, Tibshirani R J. An Introduction to the Bootstrap[M]. [S.l.]: Chapman & Hall/CRC, 1993.
- [3] Dempster A P, Laird N M, Rubin D B. Maximum Likelihood from Incomplete Data via the EM Algorithm[J]. Journal of the Royal Statistical Society: Series B, 1977, 39(1): 1-22.
- [4] McNemar Q. Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages[J]. Psychometrika, 1947, 12(2): 153-157.
- [5] Cronbach L J, Meehl P E. Construct Validity in Psychological Tests[J]. Psychological Bulletin, 1955, 52(4): 281-302.

- [6] Theis L, van den Oord A, Bethge M. A Note on the Evaluation of Generative Models[C] // Proceedings of the 4th International Conference on Learning Representations (ICLR). 2016.