

哈尔滨工业大学

硕士学位论文开题报告

题 目：基于检索增强与大语言模型后训练的
城市旅游行程规划方法研究
(学位论文)

学 院 （部）	数学学院
学科/专业学位类别	应用统计
导 师	田波平教授
研 究 生	张钧瑞
学 号	25S112072
开题报告日期	2026 年 9 月 11 日

研究生院制

目 录

1 课题来源及研究的目的和意义	1
1.1 课题来源或研究背景	1
1.2 研究的目的及意义	1
2 国内外在该方向的研究现状及分析	2
2.1 国外研究现状	2
2.2 国内研究现状	3
2.3 国内外文献综述的简析	3
3 前期的理论研究与试验论证工作的结果	3
4 学位论文的主要研究内容、实施方案及其可行性论证	4
4.1 主要研究内容	4
4.2 实施方案及其可行性论证	5
5 论文进度安排，预期达到的目标	6
5.1 进度安排	6
5.2 预期达到的目标	6
6 学位论文预期创新点	6
7 为完成课题已具备和所需的条件、外协计划及经费	6
8 预计研究过程中可能遇到的困难、问题，以及解决的途径	7
9 主要参考文献	7

1 课题来源及研究的目的和意义

1.1 课题来源或研究背景

随着大语言模型（LLM）应用边界的扩展，基于 LLM 的城市旅游行程规划系统成为文旅智能化的典型场景：用户以自然语言表达天数、预算、偏好等需求，系统输出逐日景点（POI）路线。然而，此类系统在真实落地中暴露出三个尚未解决的问题。其一，**缺乏真实语料接地导致的幻觉**：LLM 会编造不存在的地点与口碑、时序等事实细节；检索增强生成（RAG）是主流对策，但旅游场景下“真实游记经验与 POI 属性的文本级对齐语料”本身缺失，可检索的证据基础薄弱。其二，**空间行为接地不足**：在“从候选景点中选择下一站”这类空间决策上，微调后的开源 LLM 的选择质量并不稳定优于“总选最近的候选”这一简单规则——通用预训练不能替代对真实人群移动统计规律的学习，需要以后训练注入领域行为。其三，**评估方法学薄弱**：LLM 行程规划的评估普遍缺少与强规则基线的配对统计检验，对采样方差与聚合谬误缺乏控制，概率校准几乎无人检验，“LLM 是否真的更好”的结论易被评估缺陷污染。

本课题依托一个已运行的哈尔滨旅游行程规划系统（Qwen3.5-4B 微调 + 检索增强 + 规则层），将其升级为以“检索增强与后训练”为主线的规划方法研究对象。系统研制过程中积累了两项数据资产：经语义标注的 10,000 个城市 POI 库（含空间聚类与距离矩阵），以及 168 条真实游记路线（共 1,660 次相邻景点转移）——后者从未参与任何模型训练，是本课题的行为学金标准。前期分析发现真实游客的转移距离呈显著双峰形态：约半数转移发生在 2km 内的商圈尺度，其余为跨区长距离移动（中位数 1.64km，最大 195km）。围绕该数据资产，前期已完成可解释行为先验的统计建模（二阶区域转移与混合距离衰减）与三层统计评测体系——在新框架中，它们分别转化为“统计重排融合层”与“统计评测与校准层”的前期基础：前者在前期实验中使融合命中率相对最强规则基线提升约 11 个百分点，后者为全部方法提供预注册的统一裁决。

1.2 研究的目的及意义

本课题的总体目标：以真实旅游行为数据为金标准，建立“检索增强 × 后训练 × 统计重排与校准”的大语言模型行程规划方法及其三层统计评测体系。具体目标为：

1. 构建行为接地的 RAG 语料与混合检索机制：将真实游记经验（小红书笔记的自由文本）对齐到 POI 库形成可检索的证据语料，抑制幻觉并向生成过程注入真实口碑与空间结构信息；

2. 建立面向行程规划的 LLM 后训练方法：行程级监督微调（QLoRA）与以行为对数似然构造偏好对的直接偏好优化（DPO），并以统计先验重排融合约束模型输出的空间行为；
3. 建立三层统计评测体系（点层配对检验、个体层似然、群体层分布距离），克服既有评价指标与就近基线同源等方法学缺陷。

理论意义：其一，真实游记到 POI 的证据对齐给出旅游领域 RAG 语料的构建与质量评估方法，是检索增强在垂直场景落地的关键一环；其二，以统计似然构造偏好标签的后训练目标，将行为统计注入大模型优化本身，为“统计方法与大模型结合”提供新的实证形态；其三，目的地内旅游转移距离的双峰性在旅游移动文献中缺少正式检验报道，距离衰减“指数还是幂律”的长期争论将在行程内转移粒度获得数据驱动裁决。应用意义：框架直接服务于行程规划系统的工程部署；三层评测方法学可迁移至其他“LLM 对比规则”的决策场景。

2 国内外在该方向的研究现状及分析

2.1 国外研究现状

（1）下一站 POI 推荐。第一代方法以马尔可夫链与矩阵分解为主：因子化个性化马尔可夫链 FPMC^[1]、其空间扩展 FPMC-LR^[2] 与个性化排名度量嵌入 PRME^[3] 参数省、可解释，但一阶马尔可夫假设很少被正式检验。第二代深度序列模型以 ST-RNN^[4]、ARNN^[5]、长短短期偏好模型^[6] 为代表，在签到基准上精度领先，但数据饥渴、黑箱。第三代 LLM 方法将推荐转为问答或生成任务^[7,8]，近期工作进一步以多因子协作引导 LLM 完成下一站推理^[9]，零样本泛化与语义理解能力强，但存在四类系统性不足：幻觉编造 POI、空间结构弱（本项目前期实测：纯 LLM 在空间就近性上系统性输给规则）、评估缺少与强规则基线的配对统计检验、概率校准被忽视^[10]。

（2）检索增强生成与 LLM 行程规划。检索增强生成通过外挂知识库为 LLM 提供事实接地^[11]，已成为抑制幻觉的主流框架。旅游方向上，TravelRAG^[12] 以多层知识图谱组织景点检索；STrajRAG^[13] 用监督式轨迹检索增强下一 POI 生成，与本课题场景最接近；TourMLM^[14] 将检索增强扩展到多模态多任务。评估侧出现时空细粒度基准 TripCraft^[15]、个性化真实基准 TripTailor^[16] 与行程校验护栏 Iti-Validator^[17]。系统侧以“LLM 出初稿 + 算法修正”的混合架构为主流，如 RETAIL^[18] 将 LLM 与蚁群优化结合，Google 亦采用混合行程规划架构^[19]。共性不足：检索语料以结构化属性为主，真实游记经验与 POI 库的文本级对齐缺失；评估以端到端打分为主，缺少“每一站是否符合真实人类流动统计”的逐点检验。

(3) 大模型后训练。参数高效微调以 LoRA^[20] 与低比特量化的 QLoRA^[21] 为主流，使单卡低资源适配成为可能；偏好优化方面，直接偏好优化 DPO^[22] 绕开奖励模型直接以偏好对训练。但在行程规划任务上，现有后训练多为点级候选排序的指令微调，缺少行程级序列监督，更缺少以真实行为统计为信号构造偏好的工作——后训练目标与“行为符合度”之间缺乏桥梁。

(4) 本文统计层的两个方法学支柱。其一，概率融合与校准: Product of Experts^[23] 与对数意见池化理论为“乘性融合两个概率模型”提供经典框架，FuseLLM^[24] 将其用于 token 分布层融合；多专家学习延迟^[25] 与 LLM 路由^[26] 研究“何时信任哪个模型”；对齐后的 LLM 常过度自信^[10]——这些构成本课题“统计先验重排融合与校准层”的背景。其二，人类移动的距离衰减与分布形态：幂律与指数之争由来已久^[27]，个体移动距离重尾已有经典刻画^[28,29]，旅游流距离衰减见于旅游研究^[30]——但目的地内旅游转移距离的分布形态（尤其双峰性）缺少正式检验。

2.2 国内研究现状

国内团队在 LBSN 下一站推荐方向有系统性贡献：FPMC-LR^[2] 与 PRME^[3] 均为国内团队的代表性工作。LLM 方向，国内进展活跃：面向真实约束的 RETAIL 框架^[18] 将 LLM 与蚁群优化结合；《智能系统学报》近期发表了 LLM 推荐系统综述^[31] 与 LLM 个性化推荐研究^[32]，系统梳理了提示工程、模型微调与范式转变。总体上，现有工作以系统研制与综述为主，“行为接地的检索语料构建、面向行程规划的后训练、以及概率级统计重排与严格评测”的研究较少。

2.3 国内外文献综述的简析

综合现状可得三个缺口：其一，行为接地的检索语料缺失——游记富文本与 POI 库没有对齐，RAG 证据无法支撑行为合理的规划，真实转移的空间结构（如重尾）难以进入检索层；其二，面向行程规划的后训练不足——行程级序列监督与“以真实行为统计构造偏好”的后训练目标缺位；其三，评估缺数据纪律——配对统计检验、聚合谬误与过拟合控制、概率校准检验在 LLM 行程规划评估中普遍缺位。本课题的 RAG 语料构建、似然驱动偏好优化与三层评测体系分别针对这三个缺口展开。

3 前期的理论与试验论证工作的结果

前期已完成核心数据资产建设、行为先验建模、LLM 系统与后训练管线、评测体系设计与全部前置实验（代码与结果可复现）：

1. 数据资产与双峰性检验：168 条真实游记路线分层三分（拟合 84 / 权重学习 42 / 测试 42），三份分布一致性通过 KS 检验；配对 McNemar 功效分析确定测试集需覆盖全部约 372 个预测点，最小可检差异约 6 个百分点。Hartigan dip

test^[33] 在 $p < 10^{-4}$ 水平拒绝单峰；跨区分量需重尾族，最终采用 lognormal 与 log-gamma 的异质混合；

2. 行为先验建模（现统计重排层的构件）：参数自助法似然比检验支持二阶区域转移（ $p = 0.005$ ，样本外对数损失 0.62 对 0.75 nat/转移）；候选池离散选择任务上的条件 logit 拟合显示混合距离衰减形式优于任一单一形式，工程常用的纯指数形式被数据否决；
3. LLM 系统与后训练管线（新主线工程底座）：Qwen3.5-4B 4-bit 量化 + QLoRA 监督微调的完整训练与推理链已在单卡 RTX 4090 打通（一轮约 1 小时），编号候选 prompt 与首 token 概率接口实现确定性候选打分，DPO/GRPO 变体亦已验证可训练；
4. 统计重排融合的前期证据：测试集 372 点 8 选 1 任务上，统计先验单独命中率 37.1%（对就近规则 32.3%， $p = 10^{-4}$ ）；LLM 单独仅 26.6%；两者 log-linear 池化后达 43.3%（ $p \approx 0$ ）——LLM 的价值在统计重排框架下实现反转。架构消融显示距离衰减为命脉组件（去除后掉 18.8 个百分点）；
5. 三层评测体系 v1.0：以构念效度理论区分“行为符合度”与“工程质量”，预注册三层裁决规则（点层 McNemar 主裁决、个体层似然描述性、群体层分布距离），并完成生成层首轮流证（融合方法群体分布距离最优，KS = 0.219）；
6. 负结果：状态依赖融合权重与固定权重无显著差异（ $p = 1.0$ ），学得的权重塌缩为窄带常数；LLM 概率温度校准亦无实质增益（期望校准误差原始仅 0.041）。两者共同说明融合收益来自两模型误差互补的结构本身。

4 学位论文的主要研究内容、实施方案及其可行性论证

4.1 主要研究内容

论文将围绕“检索增强语料—LLM 后训练—统计重排与校准—评测体系”主线组织四章内容（研究内容以论证分析为主，非目录罗列）：

1. 行为接地的 RAG 语料构建与混合检索：POI 结构属性的卡片化文本合成；小红书游记证据到 POI 的对齐（别名归一、模糊匹配与区域约束，保守阈值加人工抽样校验并报告语料质量准确率）；稠密向量召回与规则打分的两路混合检索；检索质量评测（证据覆盖率、候选命中排名）与“纯规则/纯稠密/混合”消融。

2. 面向行程规划的 LLM 后训练：带证据 prompt 的行程级监督微调数据重建与 QLoRA 训练；以行为对数似然高低构造路线级偏好对的直接偏好优化（统计似然 → 偏好标签 → 后训练目标）；以后训练方法在三层评测与融合增益上的表现为裁决的评估协议。
3. 统计先验重排融合与概率校准：log-linear 池化的权重语义与性质；固定权重、状态依赖权重（逻辑回归堆叠、嵌套交叉验证）与硬路由的统一对比；LLM 候选概率的校准性分析（温度缩放、期望校准误差）；重排层组件必要性消融（距离衰减、区域粒度、转移阶数逐一去除检验）。
4. 三层统计评测与系统集成验证：点层（逐站命中率、Wilson 区间^[34]、配对精确 McNemar^[35]、多重比较校正^[36]）；个体层（路线行为对数似然，配对 Wilcoxon，标注其模型依赖性）；群体层（转移距离与类型节奏的 KS/Wasserstein 距离^[37]、路线级自助置信区间）；以构念效度理论^[38] 区分“行为符合度”与“工程质量”两类指标，三层互证以控制循环论证风险——该思路借鉴生成模型评测中似然与样本分布判据不可互替的论证^[39]。将 RAG、后训练与重排选择器接入行程规划管线，在生成层复验三层指标；案例分析与消融展示。

4.2 实施方案及其可行性论证

技术路线已验证：后训练与推理全链在单卡 RTX 4090 完成（LLM 4-bit 量化推理，候选打分单次前向）；语料构建为纯数据工程，无算力风险；统计重排的增益已在逐站层与生成层获得一致的前期证据（43.3% 对 32.3%，群体分布距离最优）。数据资产与代码均已版本化。可行性论证同时包含对方法本身的辩证分析：

方法合理性的有利证据：重排融合增益在点层与生成层方向一致；在已知偏向就近基线的旧工程指标下先验系方法仍然胜出，说明结论不依赖单一指标族；RAG 与后训练的每个增量均可通过三层评测独立裁决。

方法局限与对策：（1）个体似然层与重排方法共用行为统计，存在循环论证风险——对策是三层互证，裁决只依赖两层无模型指标；（2）168 条真实路线是样本硬上限，效应量检验功效受限——对策是功效前置设计与路线级自助；（3）游记证据对齐存在误配风险，错误证据会向 LLM 注入噪声——对策是保守匹配阈值、人工抽样校验并在消融中量化语料质量的影响；（4）全部生成方法都压缩了真实转移的重尾（生成分位 90 约 5km 对真实约 8km），源于候选池以当前中心检索——混合检索的全城召回本身就是针对性的缓解实验；（5）状态权重与校准的负结果提示融合收益的上限来自误差互补结构——论文将其定位为机理解释而非缺陷。

5 论文进度安排，预期达到的目标

5.1 进度安排

1. 2026.09–2026.10：完成开题；混合模型参数区间估计与分量数选择收尾；游记证据到 POI 的对齐与 RAG 语料构建；检索质量评测。
2. 2026.11–2026.12：混合检索接入；带证据 prompt 的行程级 SFT 与重排融合复验。
3. 2027.01–2027.02：中期检查；行为似然偏好对的 DPO 实验；全部消融复跑与多重比较校正固化。
4. 2027.03–2027.04：论文撰写与图表规范化；预答辩。
5. 2027.05–2027.06：修改完善、查重、答辩。

5.2 预期达到的目标

1. 建立目的地内旅游转移距离双峰性的正式建模与检验方法；
2. ”RAG + 后训练 + 统计重排”框架在真实行为数据上显著超越 LLM 基线，且不劣于已获融合结果的前期水平（43.3%）；
3. 形成可复用的 LLM 空间推荐统计评测方法学与开源代码；完成学位论文一篇，投稿学术论文一篇。

6 学位论文预期创新点

1. 实证层面：首次对目的地内旅游转移距离给出双峰性的正式检验（ $p < 10^{-4}$ ）与重尾混合参数化，并在行程粒度对距离衰减函数形式给出数据驱动裁决。
2. 方法层面：提出行为接地的 RAG 语料构建方法（真实游记证据到 POI 的对齐与质量声明）与统计似然驱动的 DPO 偏好构造，形成”检索增强—后训练—统计重排”协同的 LLM 行程规划框架；实证”LLM 单独弱于规则、经统计重排后显著反超”的价值反转，并通过组件消融论证最终架构的最简形式。
3. 评测层面：构建三层统计评测体系，系统刻画 LLM 对比规则评估中的同源性、聚合谬误与过拟合陷阱及其对策，以构念效度理论明确”行为符合度”与”工程质量”的边界。

7 为完成课题已具备和所需的条件、外协计划及经费

已具备：168 条真实游记路线与万级 POI 数据资产；全部实验代码与结果（版本管理）；RTX 4090 算力；基座模型与微调适配器（本地推理，无 API 开销）；中

文核心文献已检索补齐。所需：可能的扩展数据用于外部验证。经费需求为常规打印与差旅。

8 预计研究过程中可能遇到的困难、问题，以及解决的途径

1. **语料对齐精度**：游记自由文本与 POI 的名称匹配存在误配与漏配，错误证据会污染检索与微调。对策：保守阈值与人工抽样校验（报告准确率）；消融中量化语料质量影响；若对齐覆盖率不足，降级为“POI 卡片 + 拟合份路线模式”语料。
2. **样本量上限**：真实路线仅 168 条，细粒度检验功效受限。对策：功效前置设计；路线级自助；必要时以半参数模拟补充。
3. **循环论证风险**：个体似然与重排方法共用行为统计。对策：三层互证，裁决依赖无模型层；似然层定位为描述性。
4. **重尾压缩**：生成路线缺失真实数据中的极端长转移。对策：如实报告为共同局限；混合检索的全城召回作为针对性缓解实验并单独评测。
5. **微调的两难**：在含距离线索的证据与候选上微调，可能使 LLM 模仿就近启发式而损失语义互补性。对策：以融合增益（而非 LLM 单独精度）为后训练的裁决指标。

9 主要参考文献

- [1] Rendle S, Freudenthaler C, Schmidt-Thieme L. Factorizing Personalized Markov Chains for Next-Basket Recommendation[C] // Proceedings of the 19th International Conference on World Wide Web (WWW). 2010: 811-820.
- [2] Cheng C, Yang H, Lyu M R, et al. Where You Like to Go Next: Successive Point-of-Interest Recommendation[C] // Proceedings of the 23rd International Joint Conference on Artificial Intelligence (IJCAI). 2013: 2605-2611.
- [3] Feng S, Li X, Zeng Y, et al. Personalized Ranking Metric Embedding for Next New POI Recommendation[C] // Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI). 2015: 2069-2075.
- [4] Liu Q, Wu S, Wang L, et al. Predicting the Next Location: A Recurrent Model with Spatial and Temporal Contexts[C] // Proceedings of the 30th AAAI Conference on Artificial Intelligence (AAAI). 2016: 194-200.
- [5] Liu Q, Wu S, Wang L, et al. An Attentional Recurrent Neural Network for Personalized Next POI Recommendation[C] // Proceedings of the 33rd AAAI Conference

- on Artificial Intelligence (AAAI). 2019: 83-90.
- [6] Li X, others. Personalized Long- and Short-term Preference Learning for Next POI Recommendation[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 34(4): 1809-1822.
 - [7] Li P, de Rijke M, Xue H, et al. Large Language Models for Next Point-of-Interest Recommendation[C] // Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2024: 1393-1403.
 - [8] Wu L, Zheng Z, Qiu Z, et al. A Survey on Large Language Models for Recommendation[J]. World Wide Web, 2024, 27(5): 60.
 - [9] Song Y, Xu W, Liu L, et al. MFC4POI: Multi-Factor Collaboration for Next Point-of-Interest Recommendation Using Large Language Models[J]. Information Processing & Management, 2026, 63(2): 104824.
 - [10] Guo C, Pleiss G, Sun Y, et al. On Calibration of Modern Neural Networks[C] // Proceedings of the 34th International Conference on Machine Learning (ICML). 2017: 1321-1330.
 - [11] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C] // Advances in Neural Information Processing Systems 33 (NeurIPS). 2020: 9459-9474.
 - [12] Song S, Yang C, Xu L, et al. TravelRAG: A Tourist Attraction Retrieval Framework Based on Multi-Layer Knowledge Graph[J]. ISPRS International Journal of Geo-Information, 2024, 13(11): 414.
 - [13] Lin Z, Zhang X, Zhao K, et al. STrajRAG: Supervised Trajectory Retrieval Augmented Generation for Next POI Recommendation with Travel Semantics[J]. Information Processing & Management, 2025, 62(6): 104235.
 - [14] Yamanishi H, Xiao L, Yamasaki T. TourMLM: A Retrieval-Augmented Multimodal Large Language Model for Multitask Learning in the Tourism Domain[C] // Proceedings of the 2025 International Conference on Multimedia Retrieval (ICMR). 2025: 449-458.
 - [15] Chaudhuri S, Purkar P, Raghav R, et al. TripCraft: A Benchmark for Spatio-Temporally Fine Grained Travel Planning[C] // Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (ACL). 2025: 15355-15378.

- [16] Wang K, Shen Y, Lv C, et al. TripTailor: A Real-World Benchmark for Personalized Travel Planning[C] // Findings of the Association for Computational Linguistics: ACL 2025. 2025: 5992-6010.
- [17] Gadbail S, Desai M, Karlapalem K. Iti-Validator: A Guardrail Framework for Validating and Correcting LLM-Generated Itineraries[C] // Proceedings of the 33rd ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems. 2025: -.
- [18] Deng B, Feng Y, Liu Z, et al. RETAIL: Towards Real-world Travel Planning for Large Language Models[J]. arXiv preprint arXiv:2508.15335, 2025.
- [19] Google Research. Optimizing LLM-based Trip Planning[J]. Google Research Blog, 2025.
- [20] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models[C] // Proceedings of the 10th International Conference on Learning Representations (ICLR). 2022.
- [21] Dettmers T, Pagnoni A, Holtzman A, et al. QLoRA: Efficient Finetuning of Quantized LLMs[C] // Advances in Neural Information Processing Systems 36 (NeurIPS). 2023.
- [22] Rafailov R, Sharma A, Mitchell E, et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model[C] // Advances in Neural Information Processing Systems 36 (NeurIPS). 2023.
- [23] Hinton G E. Training Products of Experts by Minimizing Contrastive Divergence[J]. Neural Computation, 2002, 14(8): 1771-1800.
- [24] Wan F, Wan X. FuseLLM: Knowledge Fusion of Large Language Models[C] // Proceedings of the 12th International Conference on Learning Representations (ICLR). 2024.
- [25] Mao A, Mohri M, Zhong Y. Learning to Defer to Multiple Experts: Consistent Surrogate Losses[C] // Proceedings of the 26th International Conference on Artificial Intelligence and Statistics (AISTATS). 2023: -.
- [26] Ong I, Almahairi A, Wu V, et al. RouteLLM: Learning to Route LLMs with Preference Data[J]. arXiv preprint arXiv:2406.18665, 2024.
- [27] Chen Y. The Distance-Decay Function of Geographical Gravity Model: Power Law or Exponential Law?[J]. Chaos, Solitons & Fractals, 2015, 77: 174-189.

- [28] González M C, Hidalgo C A, Barabási A-L. Understanding Individual Human Mobility Patterns[J]. *Nature*, 2008, 453: 779-782.
- [29] Simini F, González M C, Maritan A, et al. A Universal Model for Mobility and Migration Patterns[J]. *Nature*, 2012, 484: 96-100.
- [30] McKercher B, Lew A A. Distance Decay and the Impact of Effective Tourism Exclusion Zones on International Travel Flows[J]. *Journal of Travel Research*, 2003, 42(2): 119-130.
- [31] 谢广明, 白彦冰, 吴子昂, et al. 基于大语言模型的推荐系统综述[J]. *智能系统学报*, 2025, 20(6): 1520-1533.
- [32] 吴国栋, 秦慧, 胡全星, et al. 大语言模型及其个性化推荐研究[J]. *智能系统学报*, 2024, 19(6): 1351-1365.
- [33] Hartigan J A, Hartigan P M. The Dip Test of Unimodality[J]. *The Annals of Statistics*, 1985, 13(1): 70-84.
- [34] Wilson E B. Probable Inference, the Law of Succession, and Statistical Inference[J]. *Journal of the American Statistical Association*, 1927, 22(154): 209-212.
- [35] McNemar Q. Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages[J]. *Psychometrika*, 1947, 12(2): 153-157.
- [36] Holm S. A Simple Sequentially Rejective Multiple Test Procedure[J]. *Scandinavian Journal of Statistics*, 1979, 6(2): 65-70.
- [37] Massey F J. The Kolmogorov-Smirnov Test for Goodness of Fit[J]. *Journal of the American Statistical Association*, 1951, 46(253): 68-78.
- [38] Cronbach L J, Meehl P E. Construct Validity in Psychological Tests[J]. *Psychological Bulletin*, 1955, 52(4): 281-302.
- [39] Theis L, van den Oord A, Bethge M. A Note on the Evaluation of Generative Models[C] // *Proceedings of the 4th International Conference on Learning Representations (ICLR)*. 2016.