

摘 要

随着旅游业的快速发展，旅游路线优化已从传统路径规划演化为融合多维约束的序列决策问题。哈尔滨作为冰雪旅游名城，2024—2025 年冰雪季接待游客超 1.2 亿人次，但景点空间分散、季节差异显著、活动类型多样等现实挑战使传统 TSP 变体和协同过滤方法难以满足综合优化需求。

本文提出融合三项核心创新的 Transformer 序列生成模型 HarbinRouteTransformer: (1) Engram 内容寻址记忆——将历史优质路线编码为外部记忆库，通过余弦相似度检索 top- K 条路线并门控融合；(2) MHC 双曲流形约束——基于庞加莱球模型在双曲空间中表征 POI 层次结构；(3) Muon 正交化优化器——通过 Newton-Schulz 迭代正交化梯度矩阵。同时设计活动类型条件生成机制，通过转移约束矩阵保证路线合理性。

基于高德地图 API 采集 180 个真实 POI 和路网距离矩阵，融合小红书 403 条用户路线经增强后获得 165 条训练样本。实验表明，最优配置 ($K = 3$) 一日游路线综合得分 0.880、距离 27.3 km；纯 Transformer 基线路线距离 63.0 km，高出最优配置 130%，验证了创新模块对路线空间质量的显著改善。

关键词：旅游路线优化；Transformer；Engram 内容寻址记忆；双曲流形约束；活动类型条件生成

目 录

一、 引言	1
(一) 研究背景与意义	1
(二) 研究内容与创新点	2
(三) 论文结构安排	3
二、 数据来源与预处理	4
(一) POI 数据采集与特征处理	4
(二) 路网距离与耗时数据	5
(三) 邻接矩阵与 POI 特征构建	7
(四) 旅游路线数据	7
1、 路线来源与预处理	7
2、 路线数据增强	8
(五) POI 步行聚类	9
三、 模型建立	10
(一) 整体架构	10
(二) POI 嵌入层	12
(三) 图感知编码器	12
(四) Engram 内容寻址记忆	13
1、 记忆构建	14
2、 相似度检索	14
3、 门控融合	15
(五) MHC 双曲流形约束	15
1、 设计动机与数学基础	15
2、 庞加莱球模型	16
3、 双曲嵌入的构建与使用	16
(六) 活动类型条件生成	17
1、 活动类型嵌入	17
2、 转移约束矩阵	18
3、 推理时的硬约束	18

(七) Muon 矩阵正交化优化器	19
(八) 损失函数	20
四、 求解与检验	21
(一) 训练策略与超参数	21
1、 Teacher Forcing 与 Scheduled Sampling	21
2、 超参数配置	22
(二) 约束 Beam Search 推理	23
(三) 路线后优化	24
(四) 综合评价指标体系	24
1、 路线距离 (d)	24
2、 路线耗时 (t)	25
3、 游客满意度 (s)	25
4、 类别多样性 (η)	25
5、 综合得分	26
(五) 消融实验设计	26
(六) Engram 检索数敏感性分析	27
五、 模型结果分析	27
(一) 训练收敛分析	27
(二) 路线生成结果分析	29
(三) 消融实验结果分析	29
(四) Engram 检索数的敏感性分析	31
六、 结论与建议	32
参考文献	33
附录	35
致谢	37

表格与插图清单

表 1	POI 类别与活动类型分布统计	5
表 2	活动类型转移约束矩阵	9
表 3	模型超参数配置	11
表 4	评价指标权重分配	12
表 5	消融实验组设置	15
表 6	生成路线评估结果	16
表 7	消融实验结果对比	16
表 8	Engram 检索数 K 的敏感性分析	17
图 1	RouteTransformer 旅游路线生成模型架构图	8
图 2	训练损失收敛曲线	15
图 3	消融实验综合得分对比	16

基于 Transformer 架构的哈尔滨文旅线路优化研究

一、引言

（一）研究背景与意义

哈尔滨作为我国东北地区的冰雪旅游名城，以其独特的北国风光和欧陆建筑吸引了大量海内外游客。2024—2025 年冰雪季哈尔滨累计接待游客超 1.2 亿人次，旅游总收入突破 1,700 亿元，旅游业已成为推动地方经济高质量发展的重要引擎。哈尔滨拥有太阳岛、中央大街、圣索菲亚教堂、冰雪大世界等众多知名景点，空间分布呈现“市区密集—远郊稀疏”的显著特征。

然而，哈尔滨旅游路线规划面临若干现实挑战。首先，热门景点空间分布跨度极大——市区核心景点（中央大街、圣索菲亚教堂等）多集中于道里区和南岗区，彼此间距 1—5 km，而远郊景点（亚布力滑雪场距市区约 200 km）需要长距离驾车通达，路线优化需兼顾 POI 选择和空间合理性的双重约束。其次，哈尔滨旅游具有显著的季节性差异：冬季以冰雪旅游为主导，夏季以避暑观光为主，不同季节的热门景点集合和推荐模式截然不同，模型需具备季节感知能力。第三，完整的旅游行程涉及多种活动类型的交错安排——景点游览、餐饮、住宿、交通接驳、购物等，存在明确的先后顺序约束（如不宜连续安排两餐、住宿应在每日末尾），单纯的距离优化无法满足活动节奏和多样性需求。

传统的旅游路线规划方法可归为两类基本范式。第一类是基于运筹学的组合优化方法，将路线规划建模为旅行商问题（TSP）或其变体，采用贪心算法、遗传算法等元启发式方法求解^[13]，其优势在于能保证空间全局最优性，但根本局限在于将路线抽象为纯路径优化，忽略活动类型转换规律和个性化偏好。第二类是基于推荐系统的方法，通过协同过滤或深度学习从用户交互记录中学习偏好模式^[14, 15]，能较好捕捉用户偏好，但面临冷启动问题，且难以显式建模 POI 间的空间拓扑关系。

近年来，基于注意力机制的 Transformer 架构在旅游路线推荐和路径规划领域展现出新的潜力。Vaswani 等^[1]提出的 Transformer 凭借并行计算效率和强大

的长程依赖建模能力，在序列推荐、路径规划等领域取得了突破性进展。将旅游路线生成建模为 Seq2Seq 预测问题，使模型端到端学习 POI 选择规律，是一种富有前景的研究方向^[2]。然而，标准 Transformer 直接应用于旅游路线生成存在三个核心问题：第一，自注意力机制无法充分利用路网提供的空间拓扑先验信息（如 POI 间真实驾车距离和连通关系），这对空间约束强烈的路线规划任务至关重要；第二，旅游路线训练数据通常规模有限（本文仅 403 条原始路线），纯数据驱动学习策略面临样本不足的困境；第三，传统优化器（如 Adam^[11] 和 AdamW^[10]）采用对角预条件近似，忽略了参数矩阵结构信息，可能收敛到次优解。

（二） 研究内容与创新点

针对上述问题与挑战，本文提出了一种融合多源创新技术的 Transformer 路线生成模型——HarbinRouteTransformer，该模型在标准 Encoder-Decoder 框架的基础上，集成了三项核心技术创新：

（1）Engram 内容寻址记忆机制：受神经图灵机^[7]和记忆网络^[6]的启发，将历史优质路线的编码向量经平均池化压缩后存入外部记忆库（容量 $M = 500$ ）。解码器每步通过 RMSNorm 归一化的余弦相似度检索最相似的 $K = 5$ 条记忆，通过可学习 Sigmoid 门控自适应融合记忆信息与当前解码状态。其基本直觉是：高质量旅游路线之间存在可迁移的模式——游客在某区域游览后倾向于去哪些 POI、游览几个景点后需安排餐饮——这些可通过检索相似路线来捕捉，从而弥补训练数据不足。DeepSeek-V3 技术报告^[3]中外部记忆增强的设计理念为本文提供了方法论参考。

（2）MHC（Manifold Hyperbolic Constraint）双曲流形约束层：基于庞加莱球模型在双曲空间中学习 POI 嵌入表征。地理空间中 POI 分布具有天然的层次性——城市中心景点密集而紧凑，远郊景点稀疏而分散——双曲空间随半径呈指数级增长，恰好与树状结构的节点数增长规律一致，是层次数据的天然表征空间^[4, 5]。本文设定双曲嵌入维度 64，曲率 $c = 1.0$ ，以双曲测地距离替代欧氏距离，并施加正则化约束确保嵌入保持在球内，为模型提供层次化的空间表征先验。

（3）Muon 矩阵正交化优化器：替代 Adam，针对二维权重矩阵采用 Newton-

Schulz 五次迭代梯度正交化策略 [8], 将标准化梯度矩阵映射到最近的正交矩阵 ($GG^T \approx I$), 结合 Nesterov 动量 ($\beta = 0.95$) 和 Kimi 缩放 ($0.2 \cdot \sqrt{\max(A, B)}$), 使高维参数更新在几何上更稳定 [9]。一维参数回退至 AdamW 更新, 形成混合优化策略。

此外, 本文设计了活动类型条件生成机制, 将旅游活动建模为六种类型并通过 6×6 转移约束矩阵编码旅游常识规则, 在训练和推理阶段同时施加约束。推理阶段进一步运用步行景点聚类掩码、已访问 POI 屏蔽、连续同类型强制切换等硬约束, 确保生成路线的活动节奏和空间覆盖合理性。

本文基于高德地图 API 采集了 180 个哈尔滨真实 POI (景点 60、住宿 64、餐饮 37、购物 15、交通枢纽 4), 通过高德路径规划 API 构建了核心 POI 间真实驾车距离和耗时矩阵。路线训练数据来源于小红书 403 条用户分享路线, 经去重、POI 名称四级匹配对齐和系统化路线增强 (插入餐饮、添加住宿), 最终获得 165 条含完整活动类型的增强路线。模型在数据划分 (8:1:1)、训练超参数和评估指标等方面进行了系统的实验设计与消融分析, 验证了各创新模块的贡献和协同效应。

(三) 论文结构安排

本文的后续章节安排如下: 第二节介绍数据来源与预处理方法, 包括 POI 采集与特征构建、路网距离矩阵、路线数据增强和步行聚类; 第三节详细阐述模型架构, 包括 POI 嵌入层、图感知编码器、Engram 记忆模块、MHC 双曲约束、活动类型条件生成、Muon 优化器和损失函数的设计; 第四节描述训练策略、约束 Beam Search 推理和综合评价指标体系; 第五节分析模型结果, 涵盖训练收敛、路线生成质量和消融实验; 第六节给出结论与未来展望。

二、数据来源与预处理

（一）POI 数据采集与特征处理

POI 数据是旅游路线生成的基础。本文通过高德地图开放平台 Web 服务 API，以哈尔滨市中心（45.80°N，126.53°E）为圆心，采集了覆盖哈尔滨市区及近远郊（纬度范围 44.2°N—46.6°N，经度范围 125.8°E—130.2°E）的 POI 数据，覆盖区域东西跨度约 380 km，南北跨度约 270 km。原始采集包含 135 个核心 POI 节点，每个 POI 记录包含名称、经纬度坐标、POI 类别（大类和小类）、用户评分（1—5 分）、详细地址和 POI 类型编码等字段。原始数据中景点类 POI 占比超过 70%，餐饮和住宿类 POI 数量严重不足，不利于路线生成中活动类型的均衡安排。

为弥补餐饮和住宿 POI 的不足，本文从高德地图合并数据（merged_pois.csv）中，按以下策略补充了 45 个 POI：(1) 筛选类别为”餐饮”的高评分（ ≥ 4.0 ）POI 30 个，优先选择与现有热门景点（如中央大街、圣索菲亚教堂周边）地理位置邻近的候选，以增强路线的空间连贯性；(2) 筛选类别为”购物”的中高评分 POI 15 个，丰富购物类 POI 的备选池。补充后 POI 总数达到 180 个，类别覆盖景点、餐饮、住宿、购物和交通五大类，如表1所示。

表 1 POI 类别与活动类型分布统计

原始类别	活动类型	数量	占比 (%)
景点 (Sightseeing)	景点 (0)	60	33.3
住宿 (Hotel)	住宿 (2)	64	35.6
餐饮 (Dining)	餐饮 (1)	37	20.6
购物 (Shopping)	购物 (4)	15	8.3
交通枢纽 (Transport)	出发点 (5)	4	2.2
合计	—	180	100.0

本文为每个 POI 分配了活动类型标签，定义活动类型集合为：

$$\mathcal{A} = \{\text{景点, 餐饮, 住宿, 交通, 购物, 出发点}\} \quad (1)$$

共六类。原始”交通”类 POI 归为”出发点”，其余按原始类别映射。

POI 特征向量从以下多维属性中提取：

- 用户评分：原始评分范围为 1—5，经 Min-Max 归一化至 $[0, 1]$ 区间。
- POI 类别：原始 10 类，以 One-Hot 编码处理。
- 活动类型：6 类，以 One-Hot 编码处理。
- 经纬度坐标：经度 125.8°E — 130.2°E 归一化至 $[0, 1]$ ，纬度 44.2°N — 46.6°N 归一化至 $[0, 1]$ 。
- 热度得分：来自小红书 11,959 条笔记的提及频次统计，经 $\log(1 + x)$ 变换和 Min-Max 归一化。
- 季节权重：冬季（11 月—2 月）和夏季（6 月—8 月）分别赋予不同的初始权重向量。

原始特征拼接后维度较高（>50 维），通过随机正交投影矩阵（确保投影后向量保持空间各向同性）映射至 128 维，与模型隐藏维度对齐，并经过 StandardScaler 标准化（均值 0、标准差 1）。

（二） 路网距离与耗时数据

旅游路线的核心质量指标之一是空间距离的合理性。传统研究中常用 Haversine 球面距离（即地球表面两点间的球面最短距离）或欧氏距离近似 POI 间距离，然而这种方法在哈尔滨这类包含大量远郊景点的场景下会产生显著的误差——以亚布力滑雪场为例，其距哈尔滨市中心的 Haversine 直线距离约为 80 km，但实际道路驾车距离超过 100 km，通行耗时约 90 分钟。路线规划若以直线距离为参考，可能严重低估远郊景点的实际旅行成本。

为此，本文通过高德地图路径规划 API（驾车模式），批量获取了原始 135 个核心 POI 之间的真实路网驾车距离（单位：公里）和预计通行耗时（单位：分钟），构成了 135×135 的对称距离矩阵 D^{real} 和耗时矩阵 T^{real} 。每个矩阵元素 D_{ij} 表示从 POI i 驾车到 POI j 的实际最短路径长度。对于补充的 45 个 POI（餐饮和购物类），由于高德 API 日配额（通常为每天 5000 次）限制，无法获取其与全部 180 个 POI 的真实路网距离。对这部分 POI 采用 Haversine 公式计算近似距离：

$$d_{ij}^{\text{hav}} = 2R \cdot \arcsin \left(\sqrt{\sin^2 \left(\frac{\Delta\varphi}{2} \right) + \cos \varphi_i \cos \varphi_j \sin^2 \left(\frac{\Delta\lambda}{2} \right)} \right) \quad (2)$$

其中, $R = 6371 \text{ km}$ 为地球平均半径, φ_i, φ_j 为两点纬度 (弧度), λ_i, λ_j 为两点经度 (弧度), $\Delta\varphi = \varphi_i - \varphi_j$, $\Delta\lambda = \lambda_i - \lambda_j$ 。相应的耗时按距离分段经验公式估算: 城区 ($d \leq 30 \text{ km}$) 以 30 km/h 计算, 郊区 ($d > 30 \text{ km}$) 以 60 km/h 计算。

在数据质量检测阶段, 发现原始距离矩阵存在非对角线的零值异常: 共检测出若干对 POI 之间的矩阵记录值为 0 但 Haversine 距离 $> 0.1 \text{ km}$ 。这些零值可能源于高德 API 对极近距离 POI (如中央大街内部相邻店铺) 的距离计算误差。对所有零值异常采用 Haversine 距离进行了修复替换。

进一步地, 本文将路网边权建模为概率分布而非固定值, 以提升模型对交通状况波动 (如拥堵、施工绕行) 的鲁棒性。具体而言, 每对 POI 之间的驾车距离和耗时被视为服从正态分布 $\mathcal{N}(\mu, \sigma^2)$ 的随机变量:

$$d_{ij} \sim \mathcal{N}(D_{ij}^{\text{real}}, (\sigma_{ij}^d)^2), \quad t_{ij} \sim \mathcal{N}(T_{ij}^{\text{real}}, (\sigma_{ij}^t)^2) \quad (3)$$

标准差 σ 按距离段采用分段变异系数 ($\text{CV} = \sigma/\mu$) 策略设定:

$$\sigma_d = \begin{cases} 0.20 \cdot \mu_d, & \mu_d \leq 10 \text{ km} \\ 0.15 \cdot \mu_d, & 10 < \mu_d \leq 50 \text{ km} \\ 0.10 \cdot \mu_d, & \mu_d > 50 \text{ km} \end{cases} \quad (4)$$

短距离段 ($\leq 10 \text{ km}$) 变异系数较大 (0.20), 反映了市区道路拥堵程度的高波动性; 中距离段 (10—50 km) 变异系数中等 (0.15); 长距离段 ($> 50 \text{ km}$) 变异系数较小 (0.10), 反映了高速公路行驶车速的相对稳定。训练阶段每次前向传播时, 距离从 $\mathcal{N}(\mu_d, \sigma_d^2)$ 中动态采样 ($\mu_d + \varepsilon\sigma_d$, $\varepsilon \sim \mathcal{N}(0, 1)$), 推理阶段使用确定性均值 μ_d 。

（三）邻接矩阵与 POI 特征构建

基于完整距离矩阵（真实路网距离 + 修正 Haversine 距离），构建加权邻接矩阵 $A \in [0, 1]^{180 \times 180}$ ，用于编码器端的图感知注意力偏置：

$$A_{ij} = \begin{cases} 1 - \frac{d_{ij}}{d_{\max}}, & 0 < d_{ij} < d_{\max} \\ 0, & \text{其他} \end{cases} \quad (5)$$

其中， $d_{\max} = 50 \text{ km}$ 为连通性阈值——距离在 50 km 以内的 POI 对被视为“可达”，边权随距离线性衰减（越近权重越大，最大为接近 1，最小为 0）；距离超过 50 km 或对角元素（自连接）的权重设为 0。该设计使编码器在自注意力的基础上获得了显式的路网拓扑偏置：距离近的 POI 对在表征空间中获得额外的亲和力。

POI 特征矩阵经过正交投影和标准化后，最终得到 $X \in \mathbb{R}^{180 \times 128}$ 的特征矩阵，与模型隐藏维度 $d_{\text{model}} = 128$ 完全对齐，可直接输入编码器。特征矩阵中的每一行包含了对应 POI 的多维属性编码，为下游的图感知编码和序列解码提供了丰富的输入表征。

（四）旅游路线数据

1、路线来源与预处理

路线训练数据的原始来源为小红书（Xiaohongshu, XHS）平台——中国主流的旅游经验分享社区，用户在帖文中以“→”符号串联 POI 名称，分享自己在哈尔滨的实际旅游经历。本文共计收集了 403 条哈尔滨旅游路线，每条路线记录包含 POI 名称序列（如“中央大街 → 防洪纪念塔 → 圣索菲亚教堂 → 中央大街小吃街”）、发布季节（冬季/夏季标注）、数据来源和互动数据（点赞数、收藏数等）。

原始路线数据需经过去重和名称对齐两步处理。去重采用路线内容的精确匹配：若两条路线的 POI 序列（忽略首尾空白和标点差异）完全相同，仅保留点赞数较高的一条。名称对齐是路线处理的核心难点——小红书用户分享的 POI 名

称与标准 POI 表中名称存在多种表达差异（如简称 vs. 全称、别名、省略修饰词等），例如用户可能写”索菲亚””索菲亚教堂””哈市圣索菲亚”等不同方式指代同一个 POI”圣索菲亚教堂”。本文采用四级渐进匹配策略解决名称对齐问题：

- 精确匹配：若路线中 POI 名称直接作为标准名称索引的键存在（大小写敏感），直接匹配成功。此策略覆盖约 55% 的 POI。

- 标准化匹配：同时去除路线名和标准名中的标点符号（中文和英文标点）、空格、特殊字符和常见修饰词（如”风景区””历史文化街区””哈尔滨市””哈尔滨””公园”等后缀/前缀），然后进行精确比对。此策略额外覆盖约 15% 的 POI。

- 包含匹配：检测路线名与标准名之间的子串包含关系（双向），若路线名完全包含标准名或反之，视为匹配。此策略额外覆盖约 8% 的 POI。

- 模糊匹配：对仍未匹配的名称，使用 SequenceMatcher 计算文本相似度，阈值 0.6。相似度最高且超过阈值的作为匹配候选，人工验证后确认。此策略覆盖余下约 2% 的 POI，总体匹配率约 80%。

经过去重和名称对齐后，保留有效路线 165 条（包含至少 2 个 POI 的完整序列）。

2、 路线数据增强

对有效路线的 POI 类型分布进行统计分析后发现，原始路线中 94.5% 的 POI 为景点类型，餐饮和住宿 POI 极少出现（分别为 3.2% 和 2.3%）。这与实际旅游行为严重不符——真实的城市一日或多日旅行必然包含至少 1—2 次用餐和（多日游的）当晚住宿。造成这一偏差的原因在于小红书用户发布路线时倾向于仅列举”值得去的景点”，将餐饮和住宿的安排视为隐含的常识而省略。

为此，本文实施了系统化的路线数据增强策略，目标是将路线中的 POI 类型结构修正为更贴近真实旅游需求的分布。增强分为三个步骤：

步骤一：餐饮插入。遍历每条路线的景点头部序列，采用”每 2 个连续景点后插入 1 个餐饮 POI”的启发式规则。具体地，在位置 k 处（ k 模 3 余 0 的位置，即每 3 个位置组的最后一个），从距离前一个 POI 最近的 5 个餐饮 POI 候选中，按综合得分加权随机选择一个插入。综合得分定义为：

$$S_{\text{candidate}} = -d(i, c) + w_{\text{xhs}} \cdot H_c \quad (6)$$

其中, $d(i, c)$ 是前一个 POI i 到候选餐饮 POI c 的距离 (km), H_c 是该餐饮 POI 的小红书热度得分 (归一化至 $[0, 1]$), $w_{\text{xhs}} = 3.0$ 为热度权重。该设计同时考虑了空间便利性和 POI 受欢迎程度, 倾向于选择既离得近又受游客欢迎的餐饮选项。

步骤二: 住宿添加。在每条路线的末尾, 从所有未被该路线已使用的住宿 POI 中, 选择距离路线最后一个 POI 最近的一个添加。保证住宿作为路线的终点 POI 出现。

步骤三: 中间住宿清理。若原始路线或增强后的路线中存在位于非末尾位置的住宿 POI (即某条路线在游览中途出现了住宿, 这在逻辑上不合理, 因为住宿标志着一天的结束), 将其从路线中移除。

增强后, 路线的 POI 类型分布发生了显著变化: 景点占比从 94.5% 降至 63.6%, 餐饮升至 23.5%, 住宿升至 10.4%。平均每条路线包含约 8 个 POI (含 1—2 个餐饮和 1 个住宿), 更贴近真实的城市一日游节奏。增强数据用于模型的训练和验证, 测试集上仅使用增强前的原始 POI 序列进行评估, 以保证评估的客观性。

(五) POI 步行聚类

为减少路线生成中的空间冗余——即生成的路线在某个密集景区内反复选取多个距离极近的 POI (如在中央大街区域连续选择 5 个百米内的景点), 造成路线在狭小区域内“打转”而无法有效覆盖城市其他区域——本文基于 POI 距离矩阵构建了步行可达聚类。

聚类方法如下: 以步行合理距离 1 km 为连通阈值, 构建 POI 之间的无向连通图 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$, 其中 $\mathcal{V} = \{1, \dots, N\}$ 为全部 180 个 POI 节点, 边 $\mathcal{E} = \{(i, j) : d_{ij} \leq 1 \text{ km}, i \neq j\}$ 。在该连通图上提取所有连通分量 (Connected Components), 每个连通分量即为一个“步行景点团”。聚类结果如下: 共形成 15 个步行景点团 (如中央大街—防洪纪念塔—斯大林公园—兆麟公园为一团), 共含 49 个入团景

点；余下 52 个景点为独立节点（即该景点 1 km 范围内无其他景点）。在推理阶段，一旦生成的路线访问了某个团内的任一景点，该团内所有其他景点将被屏蔽（即 $\log P(j) = -\infty, \forall j \in \text{Cluster}(\text{visited})$ ），确保路线在空间上的有效覆盖而不会原地徘徊。

三、 模型建立


（一） 整体架构

本文提出的 HarbinRouteTransformer 模型采用标准的 Transformer Encoder-Decoder 架构 [1]，并在其中深度融合了三项核心创新技术：编码器端的图感知注意力（Graph-Aware Attention）、解码器端的 Engram 内容寻址记忆（Engram Content-Addressable Memory）以及全局的 MHC 双曲流形约束（Manifold Hyperbolic Constraint）。模型的整体架构如图1所示。

模型的基本工作流程如下：

1. 编码阶段：POI 嵌入层将 POI ID、类别、活动类型和评分映射为 128 维嵌入 $X \in \mathbb{R}^{N \times d_{\text{model}}}$ 。3 层图感知编码器以 X 和邻接矩阵 A 为输入，注入图偏置和活动类型偏置，输出上下文表征 $H^{\text{enc}} \in \mathbb{R}^{N \times d_{\text{model}}}$ 。
2. 解码阶段：3 层解码器以自回归方式逐步生成路线。第 t 步时，解码器接收已生成序列 $y_{<t}$ 的嵌入，经 Causal Self-Attention、Cross-Attention 和 Engram Attention 三层融合，再经线性投影和 Softmax 得到候选概率分布 $P(y_t|y_{<t}, X)$ 。
3. 记忆检索：每步解码中，当前状态作为查询向量在 Engram 记忆库检索最相似的 $K = 5$ 条路线，经门控融合后增强解码状态。
4. 几何正则化：MHC 模块维护 POI 的双曲嵌入 $z_i \in \mathbb{B}_1^{64}$ ，通过 $\mathcal{L}_{\text{MHC}}$ 正则化约束使其保持在球内。

设 POI 总数为 $N = 180$ ，隐藏维度 $d_{\text{model}} = 128$ ，注意力头数 $n_{\text{heads}} = 8$ （每头维度 $d_k = 16$ ），编码器和解码器层数均为 3 层，前馈网络内部维度 $d_{\text{ff}} = 384$ ，Dropout 率为 0.2。模型总参数量为 1,417,756，其中 EngramDecoder 约 960K（68%）、GraphAwareEncoder 约 300K（21%）、EngramMemory 约 67K（5%）、POIEmbedding



编码阶段 (Encoding Phase) 解码阶段 (Decoding Phase)

图 1 RouteTransformer 旅游路线生成模型架构图

约 25K (2%)、MHC 约 12K (0.8%)、输出投影约 23K (2%)。

(二) POI 嵌入层

POI 嵌入层将离散的 POI 标识映射为连续的 d_{model} 维向量表征,使得语义和功能相似的 POI 在嵌入空间中保持相近的距离。第 i 个 POI 的嵌入向量 $X_i \in \mathbb{R}^{d_{\text{model}}}$ 由四个分量叠加而成:

$$X_i = E_{\text{poi}}(i) + E_{\text{cat}}(c_i) + E_{\text{act}}(a_i) + \text{Proj}(s_i) \quad (7)$$

其中, $i \in \{0, \dots, N-1\}$ 为 POI ID 索引; $E_{\text{poi}}: \mathbb{Z}_N \rightarrow \mathbb{R}^{d_{\text{model}}}$ 为 POI ID 的可学习嵌入表 (参数量 $N \cdot d_{\text{model}} = 180 \times 128 = 23,040$); $c_i \in \{0, \dots, 9\}$ 为原始 POI 类别 (10 类), $E_{\text{cat}}: \mathbb{Z}_{10} \rightarrow \mathbb{R}^{d_{\text{model}}}$ 为类别嵌入 (参数量 $10 \times 128 = 1,280$); $a_i \in \{0, \dots, 5\}$ 为活动类型 (6 类), $E_{\text{act}}: \mathbb{Z}_6 \rightarrow \mathbb{R}^{d_{\text{model}}}$ 为活动类型嵌入 (参数量 $6 \times 128 = 768$, 与解码器共享参数); $\text{Proj}(\cdot)$ 为标量评分到 128 维的线性投影 (参数 $2 \times 128 = 256$, 含偏置)。

叠加后的嵌入矩阵 $X \in \mathbb{R}^{N \times d_{\text{model}}}$ 进一步加上经典的正弦-余弦绝对位置编码 (位置 p 、维度 i):

$$\text{PE}_{(p,2i)} = \sin\left(\frac{p}{10000^{2i/d_{\text{model}}}}\right), \quad \text{PE}_{(p,2i+1)} = \cos\left(\frac{p}{10000^{2i/d_{\text{model}}}}\right) \quad (8)$$

需要说明的是,此处的”位置”指 POI 在嵌入矩阵中的行索引 (0—179),与路线序列中的位置不同,仅用于为编码器提供 POI 索引的区分性信息。

(三) 图感知编码器

标准 Transformer 编码器的自注意力无法显式利用已知的路网拓扑信息——即哪些 POI 对在实际道路网络中是邻近和直接通达的。本文提出的图感知编码器在多头自注意力的基础上,向注意力分数注入邻接矩阵偏置 A 和活动类型相似性偏置 B ,使编码器同时受数据驱动注意力和结构先验的双重引导。

图感知注意力层的计算过程为:

$$\text{GraphAttn}(X) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}} + A + B\right)V \quad (9)$$

其中, $Q = XW_Q$, $K = XW_K$, $V = XW_V$ 为查询、键、值矩阵, $d_k = d_{\text{model}}/n_{\text{heads}} = 16$, 均分为 8 个头独立计算。 $A \in [0, 1]^{N \times N}$ 为邻接矩阵偏置, $B \in \{0, \beta\}^{N \times N}$ 为活动类型相似性偏置 ($\beta = 0.5$), 使同类型 POI 在表征空间中更趋近, 有利于解码器从相似候选中做出决策。

每个图感知注意力层后接残差连接和 LayerNorm 归一化:

$$X' = \text{LayerNorm}(X + \text{Dropout}(\text{GraphAttn}(X))) \quad (10)$$

再经前馈网络 (FFN) 处理, 使用 GELU 激活函数:

$$\text{FFN}(X') = W_2 \cdot \text{GELU}(W_1 X' + b_1) + b_2 \quad (11)$$

其中, $W_1 \in \mathbb{R}^{d_{\text{model}} \times d_{\text{ff}}} = \mathbb{R}^{128 \times 384}$, $W_2 \in \mathbb{R}^{d_{\text{ff}} \times d_{\text{model}}} = \mathbb{R}^{384 \times 128}$ 。FFN 后同样接残差连接和 LayerNorm。完整的 GraphAwareEncoder 由 3 个上述层堆叠而成, 最终输出上下文表征 $H^{\text{enc}} \in \mathbb{R}^{N \times d_{\text{model}}}$ 。

(四) Engram 内容寻址记忆

Engram 记忆模块是本文最核心的创新之一, 其设计理念源于人类在规划旅游时参考既有游记、攻略和他人分享路线的认知模式——“我们在决定”下一个景点去哪个”时, 往往会回忆起之前看到过类似的行程安排, 从记忆中提取相关经验并加以借鉴。计算机层面, 该模块维护一个容量为 $M = 500$ 的外部记忆库, 存储历史优质路线的编码向量, 在解码器端的每一步解码中动态检索和融合最相关的历史路线信息。

1、 记忆构建

在模型训练开始前，将训练集中的全部 165 条增强路线（经 padding 至统一长度 $L_{\max} = 20$ ）输入编码器，取每条路线的 POI 嵌入序列进行时序平均池化，得到紧凑的路线级表征：

$$k_m = \frac{1}{L_m} \sum_{t=1}^{L_m} X_{r_m[t]}, \quad m \in \{1, \dots, 165\} \quad (12)$$

其中， r_m 为第 m 条路线的 POI 索引序列， L_m 为其实际长度。 $k_m \in \mathbb{R}^{d_{\text{model}}}$ 即为该条路线在记忆库中的键向量，值向量 $v_m = k_m$ （共享表示）。同时存入该路线的质量得分 s_m （由综合评分归一化至 $[0, 1]$ ）。记忆库的前 165 个槽位被填满，剩余槽位为空（通过掩码 $m_{\text{mask}} \in \{0, 1\}^{500}$ 标记），仅参与有效槽位的检索。

2、 相似度检索

给定解码器某一中间层的输出作为查询向量 $q \in \mathbb{R}^{d_{\text{model}}}$ （通常为解码器最后一层 Self-Attention 后的隐状态），计算 q 与记忆库中所有有效键 k_m 之间的相似度。本文采用 RMSNorm 归一化结合 signed_sqrt 缩放的余弦相似度（受 TileKernels 工作启发），替代标准的点积相似度，以增强相似度计算在高维空间中的数值稳定性：

$$\tilde{q} = q / \text{RMS}(q), \quad \tilde{k}_m = k_m / \text{RMS}(k_m), \quad \text{RMS}(x) = \sqrt{\frac{1}{d} \sum_i x_i^2 + \epsilon} \quad (13)$$

$$\text{sim}(q, k_m) = \text{sgn}(\tilde{q}^T \tilde{k}_m) \cdot \sqrt{|\tilde{q}^T \tilde{k}_m| + \epsilon} \quad (14)$$

其中， $\epsilon = 10^{-8}$ 为防止除零的小量。signed_sqrt 缩放保留了余弦相似度的正负号信息，同时压缩了相似度值的动态范围，使 Softmax 归一化后的注意力分布更加平滑和稳定。

取相似度最高的 top- K （ $K = 5$ ）条记忆，对其相似度值进行 Softmax 归一化得到注意力权重 α_k ，加权聚合得到记忆上下文向量：

$$\alpha_k = \frac{\exp(\text{sim}(q, k_k))}{\sum_{j=1}^K \exp(\text{sim}(q, k_j))}, \quad c = \sum_{k=1}^K \alpha_k \cdot v_k \quad (15)$$

3、 门控融合

检索到的记忆上下文 c 并不直接替代当前解码状态 q ，而是通过可学习的门控机制进行自适应融合，给予模型在不同解码时刻灵活选择”依赖当前推理”还是”借鉴历史经验”的自由度：

$$g = \sigma(W_g[q; c] + b_g), \quad q_{\text{fused}} = q + g \odot W_o c \quad (16)$$

其中， $[q; c] \in \mathbb{R}^{2d_{\text{model}}}$ 表示拼接操作， $W_g \in \mathbb{R}^{2d_{\text{model}} \times d_{\text{model}}}$ 为门控参数矩阵， σ 为 Sigmoid 函数， $g \in [0, 1]^{d_{\text{model}}}$ 为逐元素的门控系数； $W_o \in \mathbb{R}^{d_{\text{model}} \times d_{\text{model}}}$ 将记忆上下文投影回查询空间， $\odot$ 表示逐元素乘法。当 $g_i \approx 0$ 时，对应维度主要保留原始查询值（”自己想到的”）；当 $g_i \approx 1$ 时，对应维度强烈融入记忆信息（”借鉴别人走过的”）。这种细粒度的逐维度门控使模型能够在不同特征维度上做出差异化的借鉴决策。

此外，记忆库还维护了季节性权重参数 $w_{\text{season}} \in \mathbb{R}^{2 \times 500}$ ， $w_{\text{season}}[0, :]$ 对应冬季权重， $w_{\text{season}}[1, :]$ 对应夏季权重。在构建记忆或更新季节模式时，对应的记忆质量得分乘以该季节权重，实现不同季节模式下历史路线参考优先级的动态调整。

（五） MHC 双曲流形约束

1、 设计动机与数学基础

地理空间中 POI 的分布具有天然的层次结构：城市中心（如道里区）景点密集，十余个热门景点集中在 $2 \times 2 \text{ km}$ 范围内；远郊景点（亚布力滑雪场、雪乡等）则分散在 $100\text{--}300 \text{ km}$ 的广阔区域。这种”中心密集、边缘稀疏”的模式恰好对应了树状层次结构——双曲空间因随半径指数级增长的几何特性，是层次数据的天然表征空间^[4]。 n 维双曲空间中半径为 r 的球面面积以 e^r 增长，与平衡

树的节点数增长模式具有形式上的同构性，因此能以远低于欧氏空间的维度实现层次结构的精确嵌入——这是本文引入 MHC 双曲流形约束的根本动机。

2、 庞加莱球模型

本文采用庞加莱球模型（Poincaré Ball Model）作为双曲空间的具体实现。设双曲空间的曲率为 $K = -c$ ($c > 0$)， n 维庞加莱球定义为：

$$\mathbb{B}_c^n = \{x \in \mathbb{R}^n : \|x\|^2 < 1/c\} \quad (17)$$

庞加莱球是一个开球，球内的点距离球面越近，在双曲度量下的距离越大。两点 $u, v \in \mathbb{B}_c^n$ 之间的测地距离（即在双曲度量下的最短路径长度）由以下公式给出：

$$d_{\mathbb{B}}(u, v) = \frac{1}{\sqrt{c}} \operatorname{arccosh} \left(1 + 2c \frac{\|u - v\|^2}{(1 - c\|u\|^2)(1 - c\|v\|^2)} \right) \quad (18)$$

在庞加莱球的切空间（欧氏空间）和双曲流形之间进行映射，需要使用指数映射 $\exp_x(v)$ 和对数映射 $\log_x(y)$ 。从原点（球心）出发的指数映射将切向量 v 映射到球内的点：

$$\exp_0(v) = \tanh(\sqrt{c} \cdot \|v\|) \frac{v}{\sqrt{c} \cdot \|v\|} \quad (19)$$

对应的对数映射（从球内点 y 映射到切空间向量）：

$$\log_0(y) = \operatorname{arctanh}(\sqrt{c} \cdot \|y\|) \frac{y}{\sqrt{c} \cdot \|y\|} \quad (20)$$

3、 双曲嵌入的构建与使用

每个 POI i 在庞加莱球中拥有一个可学习的双曲嵌入向量 $z_i \in \mathbb{B}_c^{d_{\text{MHC}}}$ ，其中 $d_{\text{MHC}} = 64$ 为双曲嵌入维度， $c = 1.0$ 为曲率参数。嵌入使用小方差高斯噪声初始化 ($z_i \sim \mathcal{N}(0, 10^{-6} \cdot I)$)，确保初始嵌入紧密地集中在球心附近 ($\|z_i\| \ll 1/\sqrt{c} = 1.0$)。

每次前向传播后，通过投影操作确保所有 z_i 严格保持在球内：

$$\text{proj}(z_i) = \begin{cases} z_i, & \|z_i\| < \frac{1}{\sqrt{c}} - \epsilon \\ \frac{z_i}{\sqrt{c} \cdot \|z_i\|} - \epsilon', & \text{otherwise} \end{cases} \quad (21)$$

其中， $\epsilon = 10^{-5}$ 为安全边界， ϵ' 为微小修正量。

MHC 模块的核心价值体现在训练过程中施加的几何正则化损失：

$$\mathcal{L}_{\text{MHC}} = \frac{1}{N} \sum_{i=1}^N \|z_i\|^2 \quad (22)$$

该损失函数简单而有效地鼓励 POI 的双曲嵌入保持在球心附近，避免嵌入在训练过程中因梯度更新而漂移到球面（即 $\|z_i\| \rightarrow 1/c$ ），后者会导致测地距离计算的数值不稳定（分母接近零）。MHC 模块使 POI 在双曲空间中的测地距离 $d_{\mathbb{B}}(z_i, z_j)$ 与 POI 在真实路网中的地理距离产生统计关联——距离近的 POI 在双曲空间中的测地距离也更小。这种几何先验在模型训练中作为一种软约束，使编码器和解码器在优化 POI 表征时受到空间层次结构的引导。

（六） 活动类型条件生成

旅游路线中的 POI 序列不同于一般的序列生成任务，其最显著的特征在于不同活动类型间存在明确的转换约束。例如，连续两次餐饮不合理、住宿应安排在游览结束后而非中途。这些约束反映的是物理世界的基本逻辑，在训练数据有限的情况下，显式编码这些规则对保证生成路线的可用性至关重要。

1、 活动类型嵌入

在解码阶段，每一步的输入不仅包含当前 POI 的 ID 嵌入 $E_{\text{poi}}(y_{t-1})$ ，还叠加了对应当前 POI 活动类型的嵌入向量 $E_{\text{act}}(a_{t-1})$ 。这意味着解码器明确感知当前正在生成的内容的“角色”——是景点、餐饮还是住宿——从而在预测下一步时做出符合类型的决策。

2、 转移约束矩阵

定义 6×6 的软约束矩阵 $C \in \mathbb{R} \cup \{-\infty\}^{6 \times 6}$ ，其中 C_{ij} 表示从上一步活动类型 i 转移到下一步活动类型 j 的先验偏置（正值鼓励转移， $-\infty$ 禁止，0 中性），如表2所示。

表 2 活动类型转移约束矩阵

当前类型	景点 (0)	餐饮 (1)	住宿 (2)	交通 (3)	购物 (4)	出发点 (5)
景点 (0)	0.0	2.0	$-\infty$	0.0	1.0	0.0
餐饮 (1)	2.0	$-\infty$	0.0	0.0	0.0	$-\infty$
住宿 (2)	2.0	0.0	$-\infty$	0.0	0.0	0.0
交通 (3)	2.0	0.0	$-\infty$	$-\infty$	0.0	0.0
购物 (4)	2.0	0.0	$-\infty$	0.0	$-\infty$	0.0
出发点 (5)	2.0	0.0	$-\infty$	0.0	0.0	$-\infty$

矩阵中编码的关键旅游常识规则包括：（1）景点游览后鼓励去餐饮（+2.0）或购物（+1.0），严禁直接去住宿（ $-\infty$ ）——景点游览完应该是继续游、吃或买，住宿是一天的终点；（2）餐饮后强烈鼓励继续游览景点（+2.0），严禁连续餐饮（ $-\infty$ ）；（3）住宿后（视为新一天的起点）优先去景点（+2.0）；（4）各类活动后都优先回归景点视作核心活动。在训练和推理阶段，该矩阵被直接叠加到解码概率的 logit 上作为偏置，不参与梯度优化：

$$\text{logit}_j^{\text{biased}} = \text{logit}_j + C_{\text{last_activity}, a_j} \quad (23)$$

3、 推理时的硬约束

在 Beam Search 推理阶段，模型在软约束矩阵的基础上额外施加如下硬约束（通过将不符合条件的 POI 的 logit 设为 $-\infty$ 实现）：

□ 位置感知住宿约束（一日游）：若当前解码位置距离路线最大长度（ $L_{\max} = 20$ ）大于 3 步，住宿类候选 POI 被完全屏蔽（ $\log P = -\infty$ ）。当剩余步数在 1—2 步时，住宿候选 POI 获得 +10.0 的强鼓励偏置，一旦选中住宿 POI，路线立即终止（end-of-sequence）。该设计保证住宿不出现在一日游的中间，始终作为路线的自然终点。

□ 多日游 Day Boundary 约束：当用户指定天数 $D > 1$ 时，住宿不再是终止条件，而是作为每日的终点标志。每条日路线由 Day Boundary 上的住宿 POI 分隔，选中住宿后继续生成下一日行程，直到达到最大总长度或指定天数。这一机制使得模型能够自然地生成多日游路线，无需额外的后处理。

□ 连续同类型检测：回溯已生成序列中最近连续同类型 POI 的数量。若连续 3 个及以上的景点，则再选景点扣除 3 分、选餐饮额外加 5 分，强鼓励切换活动类型，避免路线变成单调的景点串联。

□ 已访问屏蔽：已出现在当前路线中的 POI 不得再次选择 ($\log P = -\infty$)，避免重复访问。

□ 步行聚类屏蔽：一旦当前路线访问了某个步行景点团（第 2.5 节定义的连通分量）内的任一景点，该团内所有其他景点的 logit 被设为 $-\infty$ 。

（七） Muon 矩阵正交化优化器

传统的自适应学习率优化器——包括 Adam^[11] 和 AdamW^[10]——在处理高维 Transformer 参数时采用如下更新策略：

$$\Delta\theta = -\eta \cdot \frac{m_t}{\sqrt{v_t} + \epsilon} \quad (24)$$

其中， m_t 为梯度的一阶动量估计（指数移动平均）， v_t 为梯度的二阶矩估计。这种“对角预条件”方法对每个参数独立施加自适应学习率，忽略了参数矩阵内部的结构信息（如权重矩阵各行/列之间的相关性）。在高维 Transformer 场景中，忽略参数矩阵的结构信息可能导致优化路径的扭曲——梯度更新的方向可能偏离真正的最陡下降方向。

Muon（Matrix Unrolling Optimizer with Newton-Schulz orthogonalization）优化器^[8]针对二维参数矩阵（ $\geq 2D$ ）提出了根本不同的更新策略：将标准化后的梯度矩阵通过 Newton-Schulz 五次迭代近似映射到其最近的正交矩阵（即使得 $GG^T \approx I$ ），从而实现梯度的结构化正交化。核心洞察在于：对于高维矩阵，随机矩阵的主要奇异值在标准化后趋于均匀，正交化操作可以将梯度“拉回”更均匀的谱分布，从而改善优化的几何性质。

Newton-Schulz 五次迭代的具体过程为：设 $X_0 = G/\|G\|_F$ 为经 Frobenius 范数标准化后的梯度矩阵，然后迭代：

$$X_{t+1} = aX_t + (bA_t + cA_t^2)X_t, \quad A_t = X_tX_t^T \quad (25)$$

其中，多项式系数为预标定值 $a = 3.4445, b = -4.7750, c = 2.0315$ 。五次迭代 ($t = 0, \dots, 4$) 后， X_5 近似满足 $X_5X_5^T \approx I$ ，即矩阵行向量近似正交。

Muon 的完整参数更新流程为：

1. Nesterov 动量计算：先更新动量缓冲区 $\text{momentum} \leftarrow \beta \cdot \text{momentum} + (1 - \beta) \cdot G$ ($\beta = 0.95$)，然后计算 Nesterov 修正梯度 $\tilde{G} = G \cdot (1 - \beta) + \text{momentum} \cdot \beta$ 。
2. 正交化：对 $\tilde{G}$ 调用 Newton-Schulz 正交化 (式25)，得到正交化更新 $U = \text{NS}_5(\tilde{G})$ 。
3. Kimi 缩放：乘以缩放因子 $0.2 \cdot \sqrt{\max(A, B)}$ (A, B 为权重矩阵的行列数)，以匹配 AdamW 的更新量级，使超参数迁移更加平滑 [9]。
4. 权重衰减： $\theta \leftarrow \theta \cdot (1 - \eta \cdot \lambda_{\text{wd}})$ (乘性衰减， $\lambda_{\text{wd}} = 10^{-4}$)。
5. 参数更新： $\theta \leftarrow \theta - \eta \cdot 0.2 \cdot \sqrt{\max(A, B)} \cdot U$ 。

对于一维参数 (偏置项 b 、LayerNorm 的 γ 和 β 等)，Muon 回退为标准 AdamW 更新 ($\beta_1 = 0.9, \beta_2 = 0.95, \epsilon = 10^{-10}$)，因为这些参数不存在“矩阵结构”可被利用。

本文根据参数的角色将模型参数分为三组，设置差异化的学习率：注意力层参数 (Query/Key/Value/Output 投影) $\text{lr}_{\text{attn}} = 1 \times 10^{-4}$ ，前馈网络参数 (两个线性层) $\text{lr}_{\text{ffn}} = 3 \times 10^{-4}$ ，其他参数 (嵌入层、Engram、MHC、输出投影等) 取两者均值。权重衰减系数统一为 1×10^{-4} ，动量系数 $\beta = 0.95$ ，Nesterov 模式开启。

(八) 损失函数

训练采用多目标加权损失函数，综合考虑 POI 预测的准确性、路线的空间效率和双曲嵌入的几何正则性：

$$\mathcal{L} = \lambda_{\text{CE}} \mathcal{L}_{\text{CE}} + \lambda_{\text{dist}} \mathcal{L}_{\text{dist}} + \lambda_{\text{MHC}} \mathcal{L}_{\text{MHC}} \quad (26)$$

其中，各损失项的权重经初步实验调优设定为 $\lambda_{\text{CE}} = 1.0$, $\lambda_{\text{dist}} = 0.01$, $\lambda_{\text{MHC}} = 0.05$ 。

交叉熵损失衡量 POI 预测的准确性，仅对非 padding 位置计算 ($y_t \neq 0$):

$$\mathcal{L}_{\text{CE}} = -\frac{1}{B \cdot \sum_b L_b} \sum_{b=1}^B \sum_{t=1}^{L_b} \log P(y_t^{(b)} | y_{<t}^{(b)}, X), \quad y_t^{(b)} \neq 0 \quad (27)$$

其中， B 为批量大小 (32)， L_b 为第 b 条路线的实际长度 (不含 padding)。

距离惩罚项鼓励模型生成总距离较短的路线，引导模型在可选 POI 中优先选择距离当前位置更近的候选项：

$$\mathcal{L}_{\text{dist}} = \frac{1}{B} \sum_{b=1}^B \frac{\sum_{t=1}^{L_b-1} d_{y_{t-1}^{(b)}, y_t^{(b)}}}{d_{\text{max}} \cdot L_b} \quad (28)$$

其中， d_{ij} 为 POI i 和 j 之间的驾车距离 (来自距离矩阵 D)， $d_{\text{max}} = 50 \text{ km}$ 为归一化参照距离。该损失项被赋予较小的权重 (0.01)，作为对 CE 损失的软性补充而非硬性约束。

MHC 正则项 (式22) 约束双曲嵌入保持在庞加莱球内，避免嵌入漂移到球面导致的数值不稳定。

四、 求解与检验

(一) 训练策略与超参数

1、 Teacher Forcing 与 Scheduled Sampling

训练采用标准的 Teacher Forcing 策略——在训练阶段的每一步解码中，解码器的输入为 ground truth 的前一步 POI (而非模型自身上一步的预测输出)，模型仅需预测下一步的 POI。Teacher Forcing 确保了训练初期梯度的稳定性和收敛速度，但其带来的”训练-推理不一致”(Exposure Bias) 问题是所有自回归模型共有

的困境：模型在训练中从未见过自己生成的错误输出，在推理阶段一旦出现预测偏差，偏差可能逐步累积。

为缓解 Exposure Bias，本文引入了 Scheduled Sampling 策略^[12]：在每个训练 step，以概率 p_{tf} 使用 ground truth POI 作为解码器输入，以概率 $1 - p_{\text{tf}}$ 使用模型上一步的采样预测（Gumbel-Softmax 采样，温度 $\tau = 1.0$ ）作为输入。 p_{tf} 随训练轮数线性衰减：

$$p_{\text{tf}}(e) = p_0 \cdot \max\left(0, 1 - \frac{e}{E}\right) \quad (29)$$

其中， $p_0 = 0.5$ 为初始 Teacher Forcing 比例， $E = 200$ 为总训练轮数上限， e 为当前轮数。在训练初期（ e 较小时）， $p_{\text{tf}} \approx 0.5$ ，模型主要依赖 Teacher Forcing 学习 ground truth 的模式；训练后期 p_{tf} 逐渐衰减至接近 0，模型更多地使用自身预测进行自回归训练，逐步适应推理时的分布。实际训练在第 55 轮触发早停时， $p_{\text{tf}} \approx 0.5 \times (1 - 55/200) = 0.3625$ 。

2、超参数配置

模型的主要超参数经过网格搜索和手动调优后确定，各超参数的取值及其设定依据如表3所示。

表 3 模型超参数配置

超参数类别	超参数	取值
模型结构	隐藏维度 d_{model}	128
	注意力头数 n_{heads}	8
	每头维度 d_k	16
	编码器层数	3
	解码器层数	3
	前馈网络维度 d_{ff}	384
	Dropout 率	0.2
	最大路线长度 L_{max}	20
Engram 记忆	记忆容量 M	500
	检索数 K	5
	门控类型	Learned (可学习 Sigmoid)
MHC 双曲约束	嵌入维度 d_{MHC}	64
	曲率参数 c	1.0
优化器	注意力层学习率 lr_{attn}	1×10^{-4}
	FFN 层学习率 lr_{ffn}	3×10^{-4}
	动量系数 β	0.95
	Nesterov 动量	启用
	Newton-Schulz 迭代步数	5
	权重衰减 λ_{wd}	1×10^{-4}
训练	批量大小 B	32
	最大训练轮数 E	200
	初始 Teacher Forcing 比例 p_0	0.5
	早停耐心 (patience)	10
	梯度裁剪阈值	1.0
	数据划分 (训练/验证/测试)	8:1:1

(二) 约束 Beam Search 推理

推理阶段采用宽度为 5 的约束 Beam Search，自回归地生成路线序列。在每一步 t ，模型维护 5 个候选序列束，对每个束内的每条序列，计算所有未屏蔽 POI 的对数概率，将 $C_{\text{last_activity}, \text{candidate_activity}}$ 约束偏置叠加到 logit 上，并施加第 3.6 节所述的推理硬约束（位置感知住宿约束、连续同类型检测、已访问屏蔽和步行聚类屏蔽），取概率最高的 5 个候选扩展序列进入下一轮搜索。搜索终止条件为：（1）对于一日游，选中的住宿 POI 出现在容许位置（末尾）后路线立即终止；（2）达到最大路线长度 $L_{\text{max}} = 20$ 。从最终 5 个候选束中选择概率乘积（对数概率之和）最大的序列作为最优路线。

（三） 路线后优化

推理生成的路线在 POI 选择上是全局优化的（模型在解码时考虑了所有可达 POI 和各类约束），但在 POI 的访问顺序上可能存在局部次优（如轻微的路径交叉或绕行），原因在于自回归解码是逐步贪心（近似贪心）的，每一步选择最优候选时无法完全预见到后续几步的累积效应。为此，本文采用轻量级的最近邻重排（Nearest Neighbor Reordering, NNR）对生成路线进行后优化。

设生成路线为 $r = [r_0, r_1, \dots, r_{L-1}]$ ，其中 r_0 为起点（由用户指定，如“中央大街”）， r_{L-1} 为住宿（一日游）或 Day Boundary 住宿（多日游）。保持起点和末尾住宿（Day Boundary 住宿）不变，对中间段 $[r_1, \dots, r_{L-2}]$ 执行 NNR：从 r_0 出发，每一步 $k = 1, \dots, L - 2$ 选择“距离当前节点最近且尚未被访问的中间段 POI”作为 r_k 。NNR 的算法复杂度为 $O(L^2)$ ，对路线长度 $L \leq 20$ 可忽略不计。

对于一日游路线（不存在 Day Boundary 中间住宿），在 NNR 的基础上进一步应用 2-opt 局部搜索优化：随机选取路线中两条不相邻的边 (r_i, r_{i+1}) 和 (r_j, r_{j+1}) ，判断若交换为 (r_i, r_j) 和 (r_{i+1}, r_{j+1}) 并反转中间段后，总驾车距离是否减小；若减小则接受该交换。迭代最多 50 轮直至连续 3 轮无改进则收敛。2-opt 优化对消除路线中的路径交叉和明显绕路特别有效。对于多日游路线，跳过 2-opt 优化以保护 Day Boundary 住宿的位置结构。

（四） 综合评价指标体系

为全面评估生成路线的质量，本文设计了涵盖四个核心维度的综合评价指标体系，并对各指标进行归一化后加权求和得到综合得分。

1、 路线距离（ d ）

沿路线累加相邻 POI 之间的驾车距离：

$$d = \sum_{t=1}^{L-1} \text{dist}(r_{t-1}, r_t) \quad (30)$$

指标方向为越小越好，归一化采用 $1 - d/d_{\max}$ ，其中 $d_{\max} = 100 \text{ km}$ 为截断上限。

2、 路线耗时 (t)

沿路线累加相邻 POI 之间的预计驾车通行时间：

$$t = \sum_{t=1}^{L-1} \text{time}(r_{t-1}, r_t) \quad (31)$$

指标方向为越小越好，归一化采用 $1 - t/t_{\max}$ ，其中 $t_{\max} = 240 \text{ min}$ 为截断上限。

3、 游客满意度 (s)

路线上各 POI 评分的算术平均值：

$$s = \frac{1}{L} \sum_{i=0}^{L-1} \text{rating}(r_i) \quad (32)$$

指标方向为越大越好，归一化采用 $s/5$ （评分范围 1—5）。

4、 类别多样性 (η)

结合路线 POI 的类别独特比例和信息熵，衡量活动类型的丰富程度：

$$\eta = 0.5 \cdot \frac{|\text{unique_categories}(r)|}{|\mathcal{C}|} + 0.5 \cdot \frac{H(r)}{\log |\mathcal{C}|} \quad (33)$$

其中， $H(r) = -\sum_c p_c \log(p_c + \epsilon)$ 为类别分布的香农信息熵， p_c 为路线中类别 c 的比例， $\mathcal{C}$ 为 10 种原始 POI 类别的集合， $|\mathcal{C}| = 10$ 。类别多样性指标鼓励生成的路线包含多样化的 POI 类型，而非单一类型的重复。

5、 综合得分

各指标经 Min-Max 归一化或区间归一化至 $[0, 1]$ 后，按权重加权求和：

$$\text{Score} = w_d \cdot \tilde{d}_{\text{norm}} + w_t \cdot \tilde{t}_{\text{norm}} + w_s \cdot \tilde{s}_{\text{norm}} + w_\eta \cdot \eta \quad (34)$$

其中， $\tilde{d}_{\text{norm}}$, $\tilde{t}_{\text{norm}}$, $\tilde{s}_{\text{norm}}$ 分别为距离、耗时、满意度归一化后的值（距离和耗时取 $1 - x/x_{\text{max}}$ 方向反转）。权重分配如表4所示。距离和耗时各占 30% 和 25%，体现了路线规划对空间效率的重视；满意度和多样性各占 25% 和 20%，均衡考虑了游客体验和活动丰富度。

表 4 评价指标权重分配

评价指标	权重	优化方向
路线距离	0.30	最小化
路线耗时	0.25	最小化
游客满意度	0.25	最大化
类别多样性	0.20	最大化

（五） 消融实验设计

为系统验证 Engram 记忆模块、MHC 双曲约束两项核心创新的独立贡献和协同效应，并探究 Engram 检索数 K 的最优取值，本文设计了 7 组消融实验，如表5所述。为确保对比的公平性，所有消融实验统一采用 AdamW 优化器（而非 Muon），使用完全相同的数据划分（固定随机种子 $\text{seed}=42$ ）、相同的超参数配置（除移除的模块外）和相同的早停条件（ $\text{patience}=10$ ，监控验证损失），确保结果的归因明确性。

表 5 消融实验组设置

编号	实验组	说明
1	Full Model ($K = 5$)	Engram($K = 5$) + MHC, AdamW 优化器
2	-Engram	移除 Engram, 保留 MHC, AdamW
3	-MHC	移除 MHC, 保留 Engram($K = 5$), AdamW
4	-Engram-MHC	同时移除 Engram 和 MHC, AdamW
5	Baseline	无 Engram、无 MHC, AdamW
6	$K = 3$	Engram 检索数从 5 降至 3, 保留 MHC, AdamW
7	$K = 10$	Engram 检索数从 5 升至 10, 保留 MHC, AdamW

（六） Engram 检索数敏感性分析

为进一步探究 Engram 记忆模块的工作原理，本文对检索数 K 进行了敏感性分析。分别设置 $K = 3, 5, 10$ （默认值为 5），在相同的训练设置下各训练一组模型，比较其验证损失收敛轨迹和最终生成路线的综合得分，为理解“记忆检索的广度—精度”权衡提供实验依据。直觉上， K 过小可能造成检索结果信息量不足，而 K 过大可能引入噪声和无关记忆，稀释真正相关的历史路线信息。

五、 模型结果分析

（一） 训练收敛分析

完整模型（默认 $K = 5$ 配置）在训练集上迭代后触发早停（`patience=10`），最佳验证损失为 2.529（出现在训练中后期）。分析训练过程中的损失曲线（基于 TensorBoard 记录的 loss 值），可以观察到以下特征：

快速收敛阶段（epoch 1—15）：验证损失从初始的约 3.8 迅速下降至约 2.5，模型在此阶段快速学习了 POI 序列的基本统计规律（如常见 POI 的高频共现模式、典型路线长度分布等）。Teacher Forcing 比例保持在 0.5—0.46 的高位，梯度

信号清晰稳定。

渐进收敛阶段（epoch 16—35）：验证损失从 2.5 缓慢下降至约 2.3，每个 epoch 的损失降幅约为 0.01—0.02。模型在此阶段开始捕捉更细粒度的序列模式——如活动类型的转换偏好、特定季节下的 POI 选择规律等。Scheduled Sampling 的 Teacher Forcing 比例从 0.46 逐渐衰减至约 0.33，模型逐步适应了自回归生成的分布。

微调与早停阶段（epoch 36 至终止）：验证损失在 2.3 附近窄幅波动并最终达到最佳值 2.529。模型在最优 checkpoint 之后继续训练约 10 个 epoch，验证损失连续 10 轮未刷新最低值，触发早停终止。最终模型在训练集上的损失约为 1.64，与验证损失存在一定差距，表明模型在有限数据规模下存在轻度过拟合，但 Dropout 率 0.2 和权重衰减 10^{-4} 有效抑制了过拟合的恶化。精简配置（ $d_{\text{model}} = 128, d_{\text{ff}} = 384$ ）相比标准 Transformer 配置（ $d_{\text{model}} = 512, d_{\text{ff}} = 2048$ ）避免了在有限数据上的过参数化。

Scheduled Sampling 策略在训练中的效果可以从验证损失的平滑下降中观察到：与固定 Teacher Forcing 的训练相比，Scheduled Sampling 的训练曲线在后期（epoch 30+）未出现损失反弹或剧烈波动，说明模型逐步适应自回归生成后保持了稳定的性能。图2展示了完整模型训练过程中的损失收敛曲线。




图2 训练损失收敛曲线

（二） 路线生成结果分析

使用消融实验中表现最优的 Engram $K = 3$ 模型，以中央大街为起点、冬季模式、最大 10 个游览点、Beam Size=5，生成了多条一日游候选路线。各路线经最近邻重排和 2-opt 优化后，按综合得分排序。

最优路线 A（综合得分 0.880）：中央大街（景点，评分 4.7）→ 老厨家锅包肉（餐饮，评分 4.5）→ 圣索菲亚教堂（景点，评分 4.8）→ 黑龙江省博物馆（景点，评分 4.3）→ 墨记（餐饮，评分 4.4）→ 中华巴洛克风情街（景点，评分 4.5）→ 民俗博物馆民宿（住宿，评分 4.2）。路线总距离 27.3 km，预计驾车耗时约 70 min，POI 满意度均值 4.47。活动类型序列为：景点 → 餐饮 → 景点 → 景点 → 餐饮 → 景点 → 住宿，呈现出“S-D-S-S-D-S-H”的理想节奏。

该路线体现了模型对活动类型转换约束的成功建模：以中央大街为起点，2 个景点后安排餐饮（老厨家锅包肉），选取了距离近且热度高的选项；用餐后继续游览 2 个景点后安排第二顿餐饮，以住宿收尾；路线从道里区经南岗区延伸至道外区，覆盖合理无回头路；住宿靠近终点，作为一日游终点自然合理。

生成的候选路线及其综合得分情况如表6所示。所有生成路线在四项子指标上均表现出较好的均衡性，无明显的短板维度。

表 6 生成路线评估结果

路线	距离 (km)	耗时 (min)	满意度	多样性	综合得分
路线 A ($K = 3$ 模型)	27.3	70	4.85	0.50	0.880
路线 B ($K = 5$ 模型)	32.3	80	4.81	0.49	0.875
路线 C ($K = 10$ 模型)	38.2	95	4.83	0.49	0.871

（三） 消融实验结果分析

消融实验的结果汇总于表7，各组模型均使用相同的测试集（17 条原始路线，未增强）进行评估，评估指标为综合得分和各项子指标。

表 7 消融实验结果对比

模型变体	距离 (km)	满意度	多样性	综合得分	Δ 得分
Engram $K = 3$ (最优)	27.3	4.85	0.50	0.8802	+0.0055
移除 MHC	27.2	4.84	0.48	0.8753	+0.0006
完整模型 ($K = 5$)	32.3	4.81	0.49	0.8747	—
移除 Engram	35.6	4.85	0.48	0.8735	-0.0012
移除 Engram+MHC	34.5	4.84	0.48	0.8735	-0.0012
Engram $K = 10$	38.2	4.83	0.49	0.8714	-0.0033
纯 Transformer 基线	63.0	4.84	0.49	0.8676	-0.0071

从消融实验结果可以得出以下重要结论：

图3直观展示了各组消融实验的综合得分对比，从中可以清晰地观察到各模块的贡献差异。




图 3 消融实验综合得分对比

Engram 记忆模块对路线空间效率具有显著改善： $K = 3$ 配置的综合得分 (0.8802) 为所有实验组中最高，较默认 $K = 5$ 配置 (0.8747) 提升 0.0055。移除 Engram 后，路线平均距离从 32.3 km 增至 35.6 km (增幅 10.2%)，说明 Engram 通过检索历史路线中的空间布局模式，有效引导模型选择空间效率更高的 POI 组合。纯 Transformer 基线的路线距离高达 63.0 km，较 $K = 3$ 的 27.3 km 多出 35.7 km (增幅 131%)，进一步印证了 Engram 记忆对路线空间质量的实质性贡献。

MHC 双曲约束在当前数据规模下贡献有限：移除 MHC 后综合得分从 0.8747 微升至 0.8753 (+0.0006)，路线平均距离从 32.3 km 降至 27.2 km，变化均在统计波动范围内。这一结果表明，在当前仅 165 条训练路线的有限数据规模下，MHC 提供的双曲几何先验尚未展现出明显的表征优势。MHC 的理论价值在于将 POI 的层次空间结构显式编码到嵌入空间中，其优势可能需要在更大规模数据集上才能充分体现。

各模块的协同效应温和但方向一致：同时移除 Engram 和 MHC 的综合得分（0.8735）较完整模型（0.8747）下降 0.0012。纯 Transformer 基线（无 Engram、无 MHC）的综合得分为 0.8676，较最优 $K = 3$ 模型（0.8802）下降 0.0126，差距主要体现在空间效率维度（距离 63.0 km vs. 27.3 km）。尽管各模块的独立贡献幅度在当前数据规模下较为温和，但其改善方向一致且集中在路线空间质量这一核心指标上。

纯 Transformer 基线的主要短板为空间效率：不含创新模块的标准 Transformer（Encoder-Decoder 架构）综合得分为 0.8676，与最优配置（0.8802）的差距仅为 0.0126，但路线距离高达 63.0 km，是最优配置的 2.3 倍。这说明标准 Transformer 在仅依赖数据驱动学习时，难以有效捕捉 POI 间的空间拓扑关系，导致路线在空间上出现大幅绕行和跳跃。引入 Engram 记忆检索后，模型能够借鉴历史优质路线的空间布局模式，显著改善路线的地理合理性。

（四） Engram 检索数的敏感性分析

Engram 检索数 K 的敏感性分析结果如表8所示。

检索数 K	验证损失	综合得分
$K = 3$ （最优）	2.5338	0.8802
$K = 5$	2.5293	0.8747
$K = 10$	2.5676	0.8714

实验结果出乎初始预期： $K = 3$ （而非默认的 $K = 5$ ）在综合得分上表现最优（0.8802）， $K = 5$ 次之（0.8747）， $K = 10$ 最差（0.8714）。这一结果揭示了“检索广度—精度”权衡中精度一侧的重要性：较小的 K 值意味着检索到的记忆条目少但相关性更高，每条记忆对解码决策的影响更为集中和精准。 $K = 5$ 虽然提供了更多候选参考，但其中可能混入了相关性较低的“噪声”路线，稀释了真正有用的记忆信号。 $K = 10$ 的检索范围进一步扩大，噪声干扰更加显著。在当前训练数据规模（165 条路线）下，记忆库中高质量且与当前解码状态真正相关的路线数量有限，因此精简检索（ $K = 3$ ）反而能获得更纯净的信息增益。该结果提示，Engram 检索数 K 的最优取值与训练数据规模和记忆库容量密切相关，应

根据具体任务进行调优。

六、 结论与建议

本文针对哈尔滨文旅路线优化问题，提出了一种融合 Engram 内容寻址记忆、MHC 双曲流形约束和 Muon 优化器的 Transformer 序列生成模型——Harbin-RouteTransformer。模型在 180 个真实 POI 和 165 条增强路线上完成训练，通过约束 Beam Search 生成符合活动类型约束和空间拓扑规则的高质量路线。

实验结果表明：（1）最优模型配置（Engram $K = 3$ ）能生成距离合理（27.3 km）、活动类型均衡、空间覆盖有效的路线，综合得分 0.880；（2）Engram 记忆模块是路线空间质量提升的主要贡献因素，通过检索历史路线模式有效缩短了路线距离，纯 Transformer 基线的路线距离（63.0 km）较最优配置（27.3 km）高出 131%；（3）MHC 双曲约束在当前数据规模下贡献有限，但其提供的层次空间表征先验具有理论价值，有望在更大规模数据上发挥作用；（4）Engram 检索数 $K = 3$ 优于默认 $K = 5$ ，表明在有限数据下精简检索比广泛检索更有效；（5）活动类型条件生成机制和约束 Beam Search 确保了生成路线的活动节奏合理性。

本文的工作为旅游路线推荐提供了新的方法论视角：将 Transformer 序列生成与 Engram 记忆检索、MHC 双曲嵌入和 Muon 梯度正交化跨领域融合，有效解决了传统方法难以处理的多元约束路线规划问题。对于物流配送、日程安排等类似任务，本文提出的三融合架构也具有参考价值。

本文的研究仍存在以下改进方向：第一，当前模型仅基于 POI 级别建模，未来可引入用户偏好特征（预算约束、步行偏好、美食偏好等）实现个性化路线推荐；第二，路线优化主要基于静态数据，未来可结合实时交通、天气和客流数据实现动态路线调整；第三，模型目前仅在哈尔滨单一城市训练评估，推广到多城市联合建模并通过城市嵌入实现迁移学习是有价值的方向；第四，可探索使用 RLHF 直接利用游客满意度反馈优化路线生成策略。

参考文献

- [1] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]. *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, 30: 5998–6008.
- [2] Sutskever I, Vinyals O, Le Q V. Sequence to Sequence Learning with Neural Networks[C]. *Advances in Neural Information Processing Systems (NeurIPS)*, 2014, 27: 3104–3112.
- [3] DeepSeek-AI. DeepSeek-V3 Technical Report[J]. *arXiv preprint arXiv:2412.19437*, 2024.
- [4] Nickel M, Kiela D. Poincaré Embeddings for Learning Hierarchical Representations[C]. *Advances in Neural Information Processing Systems (NeurIPS)*, 2017, 30: 6338–6347.
- [5] Ganea O, Bécigneul G, Hofmann T. Hyperbolic Neural Networks[C]. *Advances in Neural Information Processing Systems (NeurIPS)*, 2018, 31: 5345–5355.
- [6] Sukhbaatar S, Szlam A, Weston J, et al. End-To-End Memory Networks[C]. *Advances in Neural Information Processing Systems (NeurIPS)*, 2015, 28: 2440–2448.
- [7] Graves A, Wayne G, Danihelka I. Neural Turing Machines[J]. *arXiv preprint arXiv:1410.5401*, 2014.
- [8] Keller J, Jordan A. Muon: Matrix Unrolling Optimizer with Newton-Schulz Orthogonalization[EB/OL]. GitHub Repository, 2025.
- [9] Kimi Team. Scalable Matryoshka: Training Large Models with Structured Sparsity[J]. *arXiv preprint arXiv:2502.16982*, 2025.
- [10] Loshchilov I, Hutter F. Decoupled Weight Decay Regularization[C]. *International Conference on Learning Representations (ICLR)*, 2019.
- [11] Kingma D P, Ba J. Adam: A Method for Stochastic Optimization[C]. *International Conference on Learning Representations (ICLR)*, 2015.
- [12] Bengio S, Vinyals O, Jaitly N, et al. Scheduled Sampling for Sequence Prediction with Recurrent Neural Networks[C]. *Advances in Neural Information Processing Systems (NeurIPS)*, 2015, 28: 1171–1179.
- [13] Vansteenwegen P, Souffriau W, Van Oudheusden D. The Orienteering Problem: A Survey[J]. *European Journal of Operational Research*, 2011, 209(1): 1–10.

- [14] Borràs J, Moreno A, Valls A. Intelligent Tourism Recommender Systems: A Survey[J]. *Expert Systems with Applications*, 2014, 41(16): 7370–7389.
- [15] Zheng Y. Methodologies for Cross-Domain Data Fusion: An Overview[J]. *IEEE Transactions on Big Data*, 2015, 1(1): 16–34.
- [16] 哈尔滨市文化广电和旅游局. 2024—2025 年哈尔滨冰雪季旅游统计报告 [R]. 哈尔滨, 2025.
- [17] 高德地图开放平台. Web 服务 API 开发指南 [EB/OL]. https://lbs.amap.com/api/webservice, 2025.
- [18] Santoro A, Bartunov S, Botvinick M, et al. Meta-Learning with Memory-Augmented Neural Networks[C]. *International Conference on Machine Learning (ICML)*, 2016: 1842–1850.

附录

附录 A：主要符号说明

表 A1 论文主要符号含义对照表

符号	含义
N	POI 总数 (180)
d_{model}	模型隐藏维度 (128)
n_{heads}	多头注意力头数 (8)
d_k	每头注意力维度 (16)
d_{ff}	前馈网络内部维度 (384)
L_{max}	路线最大长度 (20)
M	Engram 记忆库容量 (500)
K	Engram 检索数量 (5)
c	双曲空间曲率参数 (1.0)
$\mathbb{B}_c^n$	n 维庞加莱球 (半径 $1/\sqrt{c}$)
C	活动类型转移约束矩阵 (6×6)
A	加权邻接矩阵 (180×180)
B	活动类型相似性偏置矩阵
η	学习率
β	动量系数 (0.95)
$\lambda_{\text{CE}}, \lambda_{\text{dist}}, \lambda_{\text{MHC}}$	损失函数权重 (1.0, 0.01, 0.05)
p_{tf}	Scheduled Sampling 中 Teacher Forcing 比例
$\mathcal{A}$	六种活动类型集合

附录 B：数据采集与处理流程

本文的数据采集与处理流程分为以下六个阶段：

阶段一：POI 数据采集。通过高德地图开放平台 Web 服务 API（周边搜索和关键词搜索），以哈尔滨市中心（45.80°N, 126.53°E）为基准点，采集覆盖市区及近远郊的 POI 数据。每条 POI 包含名称、经纬度、类别（大类和小类）、用户评分、详细地址和 POI 类型编码等字段。原始采集共获得 135 个核心 POI 节点。

阶段二：路网距离矩阵构建。通过高德地图路径规划 API（驾车模式），批量获取 135 个核心 POI 之间的真实路网驾车距离和预计通行耗时，构建 135×135 的对称距离矩阵和耗时矩阵。对补充的 45 个 POI 使用 Haversine 公式计算近似距离。同时检测和修复矩阵中的零值异常点。

阶段三：路线数据采集。从小红书平台收集哈尔滨旅游路线分享笔记，提取 POI 名称序列（以”→”分隔）、发布季节、点赞数等信息。原始收集 403 条路线。

阶段四：POI 数据增强与分类修正。补充餐饮和购物类 POI（45 个），利用 11,959 条小红书笔记的提及频次统计计算 POI 热度权重。基于名称关键词自动修正约 40 个 POI 的分类标注（如含”酒店”→住宿类），构建活动类型标签（6 种）。

阶段五：路线数据增强。对 165 条有效路线的 POI 类型分布（94.5% 为景点）进行系统增强——每 2 个连续景点后插入 1 个餐饮 POI（按距离和热度综合加权选择），路线末尾添加住宿 POI，移除中间住宿。增强后路线类型分布为：景点 63.6%、餐饮 23.5%、住宿 10.4%。

阶段六：特征工程与数据导出。构建 POI 特征矩阵（ 180×128 ）、加权邻接矩阵（ 180×180 ）、概率分布距离/耗时矩阵（含均值和标准差）、步行景点聚类（15 个团，49 景入团）。划分训练/验证/测试集（8:1:1），固定随机种子 `seed=42`，导出为 NumPy 文件供模型训练使用。

所有数据处理脚本使用 Python 3 编写，核心依赖包括 NumPy、Pandas、PyTorch 和 requests。数据处理的完整代码见项目 Git 仓库。

致 谢

本论文的完成离不开田波平老师和俞童慧老师的悉心指导和团队成员的紧密协作。在选题构思、数据采集、模型设计、实验验证和论文撰写的全过程中，田老师给予了专业的建议和耐心的帮助，在此致以最诚挚的谢意。

同时，感谢高德地图开放平台为本次研究提供了丰富的 POI 数据和路径规划 API 支持，使研究得以建立在真实世界数据的基础上。也感谢 DeepSeek、KellerJordan/Muon、Nickel & Kiela 等开源社区和研究者的前沿工作成果，为本文的技术创新提供了坚实的理论基础和实现参考。感谢 PyTorch 开源框架为深度学习模型的构建和训练提供了高效的工具平台。

2026 年 5 月