

摘 要

随着我国旅游业的快速发展和游客个性化需求的日益增长，旅游路线优化问题成为智慧旅游研究的核心课题。哈尔滨作为我国东北地区重要的冰雪旅游城市，其旅游路线规划面临景点分布分散、季节差异显著、活动类型多样等独特挑战。本文针对哈尔滨文旅路线优化问题，提出了一种基于 Transformer 架构的序列到序列生成模型——HarbinRouteTransformer。该模型融合了三项核心技术创新：（1）Engram 内容寻址记忆模块，从历史优质路线中检索相似片段以辅助当前解码决策；（2）MHC（Manifold Hyperbolic Constraint）双曲流形约束层，基于庞加莱球模型在双曲空间中表征 POI 的层次化地理关系；（3）Muon 矩阵正交化优化器，通过 Newton-Schulz 迭代实现梯度的正交化更新。在此基础上，本文设计了活动类型条件生成机制，将旅游活动建模为六类（景点、餐饮、住宿、交通、购物、出发点）并通过转移约束矩阵引导模型生成符合真实旅游节奏的路线。实验基于 180 个哈尔滨真实 POI 和 165 条增强路线数据进行训练，模型参数量约 142 万。训练采用 Teacher Forcing 与 Scheduled Sampling 策略，推理阶段使用约束 Beam Search 结合步行景点聚类感知掩码。本文设计了涵盖距离、时间、满意度和多样性四个维度的综合评估指标体系，并通过消融实验验证了各创新模块的独立贡献。实验结果表明，模型能够生成距离合理、活动类型均衡的高质量旅游路线，综合得分达 0.897，优于各消融变体，验证了所提方法的有效性。

关键词：旅游路线优化；Transformer；Engram 记忆；双曲流形约束；活动类型条件生成

目 录

表格与插图清单	4
1 引言	1
2 数据来源与预处理	2
2.1 POI 数据采集与处理	2
2.2 路网距离与耗时数据	3
2.3 邻接矩阵与 POI 特征构建	4
2.4 旅游路线数据	4
2.4.1 POI 名称对齐	4
2.4.2 路线数据增强	4
2.5 POI 步行聚类	5
3 模型建立	5
3.1 整体架构	5
3.2 POI 嵌入层	5
3.3 图感知编码器	6
3.4 Engram 内容寻址记忆	6
3.5 MHC 双曲流形约束	7
3.6 活动类型条件生成	7
3.7 Muon 矩阵正交化优化器	8
3.8 损失函数	9
4 求解与检验	9
4.1 训练策略	9
4.2 约束 Beam Search 推理	10
4.3 路线后优化	11
4.4 评估指标体系	11
4.5 消融实验设计	12
5 模型结果分析	12
5.1 训练收敛分析	12

5.2 路线生成结果分析	13
5.3 消融实验结果	13
6 结论与建议	14
参考文献	16
附录	18
致谢	20

表格与插图清单

表 1	POI 类别分布统计	5
表 2	活动类型转换约束矩阵	8
表 3	模型超参数配置	10
表 4	评价指标权重分配	11
表 5	消融实验结果对比	14
表 6	生成路线评估结果	15
图 1	RouteTransformer 模型整体架构	7
图 2	Engram 内容寻址记忆工作流程	8
图 3	庞加莱球模型与双曲嵌入示意	9
图 4	训练损失收敛曲线	13
图 5	最优一日游路线地图可视化	15
图 6	消融实验综合得分对比	14

基于 Transformer 架构的哈尔滨文旅线路优化研究

引言

哈尔滨作为我国东北地区的冰雪旅游名城，以其独特的北国风光、欧陆建筑和冰雪文化吸引了大量海内外游客。据统计，2024—2025 年冰雪季哈尔滨累计接待游客超过 1.2 亿人次，旅游业已成为推动地方经济发展的重要引擎。然而，哈尔滨旅游路线规划面临若干现实挑战：其一，热门景点空间分布较为分散，市区景点与远郊景点（如亚布力滑雪场、雪乡等）之间距离可达数十至上百公里，路线优化对于提升游客体验和控制出行成本至关重要；其二，哈尔滨旅游具有显著的季节性差异，冬季以冰雪项目为主，夏季则以避暑观光为主，不同季节的热门景点和推荐路线存在明显差异；其三，一次完整的旅游行程涉及多种活动类型——景点游览、餐饮、住宿、交通接驳、购物等，各类活动之间存在合理的先后顺序约束（如不宜连续安排餐饮、住宿应安排在每日末尾），单纯的距离优化无法满足游客对旅游节奏和活动多样性的需求。

传统的旅游路线规划方法主要有两类：一类是基于运筹学的路径优化方法，将旅游路线规划建模为旅行商问题（TSP）或其变体，采用贪心算法、遗传算法等元启发式方法求解。此类方法虽然能保证路线在空间上的高效性，但忽略了活动类型的转换约束和游客的个性化偏好，生成的路线通常是纯景点序列，缺乏对餐饮、住宿等配套服务的合理安排。另一类是基于推荐系统的方法，通过协同过滤或矩阵分解为用户推荐景点和路线，但这类方法往往依赖大量用户历史行为数据，且难以显式地建模 POI 之间的空间拓扑关系和活动类型转换规律。

近年来，基于深度学习的序列生成模型在旅游路线推荐领域展现出新的潜力。Transformer 架构凭借其强大的序列建模能力和灵活的注意力机制，在自然语言处理、路径规划等领域取得了突破性进展。然而，将标准 Transformer 直接应用于旅游路线生成面临三个核心问题：第一，标准 Transformer 无法充分利用路网提供的空间拓扑先验信息（如 POI 之间的连通关系和真实通行距离）；第二，模型缺乏对历史优质路线的有效“记忆”和“借鉴”能力，难以从有限的训练数据中学习到通用的路线规划模式；第三，传统的优化器（如 Adam）在处理高维参数空间时可能收敛到次优解。

针对上述问题，本文提出了一种融合三项核心优化的 Transformer 路线生成模型——HarbinRouteTransformer。模型的主要创新点如下：

(1) 引入 Engram 内容寻址记忆机制，将历史优质路线的编码向量存储为外部记忆库，在解码过程中通过余弦相似度检索最相似的 top-k 条历史路线，并通过可学习门控机制自适应地融合历史经验与当前解码状态。

(2) 构建 MHC 双曲流形约束层，基于庞加莱球（Poincaré Ball）模型在双曲空间中学习 POI 嵌入表征。双曲空间的负曲率特性使其能够自然地表示树状

或层次化结构——城市中心的密集景点与远郊的稀疏景点在双曲空间中呈现出更合理的几何关系，测地距离能够更好地反映真实地理距离的层次性。

(3) 采用 Muon 矩阵正交化优化器替代传统 Adam 优化器。Muon 通过 Newton-Schulz 五次迭代对梯度矩阵进行近似正交化，结合 Nesterov 动量和 Kimi 缩放，在处理高维权重矩阵时展现出更稳定的收敛特性。

此外，本文设计了活动类型条件生成机制，将旅游活动建模为景点、餐饮、住宿、交通、购物、出发点六种类型，并通过 6×6 转移约束矩阵和推理阶段的硬约束（如住宿仅在路线末尾出现、连续同类型强制切换等），保证生成路线的活动节奏符合真实旅游习惯。同时，基于步行距离的 POI 聚类掩码机制有效避免了路线的空间冗余。

本文基于高德地图采集的 180 个哈尔滨真实 POI 和 403 条小红书旅游路线数据进行实验，模型训练收敛后生成的一日游路线综合得分达 0.897，消融实验验证了各创新模块对模型性能的独立贡献。

数据来源与预处理

POI 数据采集与处理

POI (Point of Interest, 兴趣点) 数据是旅游路线生成的基础。本文通过高德地图开放平台 API，以哈尔滨市中心 (45.80°N , 126.53°E) 为圆心，采集了覆盖市区及远郊 (纬度范围 44.2°N — 46.6°N ，经度范围 125.8°E — 130.2°E) 的 POI 数据。原始采集包含 135 个核心 POI 节点，涵盖景点、餐饮、住宿、交通、购物五大类别。每条 POI 记录包含名称、经纬度坐标、类别、评分、地址、POI 类型等字段。

由于原始核心节点以景点为主 (占比超过 70%)，餐饮和住宿类 POI 数量不足，不利于路线生成中的活动类型均衡。因此，本文从高德地图的合并数据中补充了 30 个餐饮 POI 和 15 个购物 POI，使 POI 总数扩展至 180 个。补充策略为：按类别筛选高分 POI，优先选择与现有景点地理位置接近的候选，以增强路线的连贯性。

对于 POI 的分类标注，本文采用自动修正策略：遍历所有 POI 名称，若名称中包含“酒店”“宾馆”“民宿”“客栈”“旅馆”等关键词，则将其类别修正为“住宿”；若包含“餐厅”“饭店”“小吃”“火锅”“烧烤”等关键词，则修正为“餐饮”。该策略自动修正了约 40 个 POI 的分类标注，有效提升了数据质量。

同时，本文为每个 POI 分配了活动类型标签。设活动类型集合为 $\mathcal{A} = \{\text{景点}(0), \text{餐饮}(1), \text{住宿}(2), \text{交通}(3), \text{购物}(4), \text{出发点}(5)\}$ ，共六类。活动类型的判定规则为：原始类别为“交通”的 POI（如火车站、机场）归为“出发点”类型，其他 POI 按原始类别直接映射。处理后 180 个 POI 的类别与活动类型分布如表 1 所示。

表 1 POI 类别分布统计

类别（活动类型）	数量	占比（%）
景点（景点）	60	33.3
住宿（住宿）	64	35.6
餐饮（餐饮）	37	20.6
购物（购物）	15	8.3
交通（出发点）	4	2.2
合计	180	100.0

路网距离与耗时数据

传统研究中常用 Haversine 球面距离或欧氏距离近似 POI 间距离，这种方法在哈尔滨这类包含大量远郊景点的场景下会产生显著误差（亚布力滑雪场距市中心直线距离约 80km，但实际道路距离超过 100km）。为此，本文通过高德地图路径规划 API，批量获取了原始 135 个核心 POI 之间的真实路网驾车距离和通行耗时，构建了 135×135 的距离矩阵（单位：公里）和耗时矩阵（单位：分钟）。

对于补充的 45 个 POI，由于高德 API 配额限制，其与所有 POI 间的距离通过 Haversine 公式计算：

$$d_{ij} = 2R \cdot \arcsin \left(\sqrt{\sin^2 \left(\frac{\Delta\varphi}{2} \right) + \cos \varphi_i \cos \varphi_j \sin^2 \left(\frac{\Delta\lambda}{2} \right)} \right) \quad (1)$$

其中， $R = 6371\text{km}$ 为地球半径， φ_i, φ_j 为两点纬度， λ_i, λ_j 为两点经度。耗时按距离分段估算：城区（ $d \leq 30\text{km}$ ）以 30km/h 计算，郊区（ $d > 30\text{km}$ ）以 60km/h 计算。

在数据分析过程中，发现原始距离矩阵存在非对角线零距离的异常值（共检测出若干对 POI 的矩阵值为 0 但 Haversine 距离 $> 0.1\text{km}$ ），这些零值可能源于高德 API 对极近距离 POI 的处理误差。本文采用 Haversine 距离对这些零值进行了修复。

进一步地，本文将路网边权建模为概率分布而非固定值，以提升模型的鲁棒性。具体而言，距离和耗时均被视为服从正态分布 $\mathcal{N}(\mu, \sigma^2)$ 的随机变量，其中均值 μ 为矩阵中的记录值，标准差 σ 按距离段采用不同的变异系数（ $\text{CV} = \sigma/\mu$ ）：

$$\sigma_d = \begin{cases} 0.20 \cdot \mu_d, & \mu_d \leq 10\text{km} \\ 0.15 \cdot \mu_d, & 10 < \mu_d \leq 50\text{km} \\ 0.10 \cdot \mu_d, & \mu_d > 50\text{km} \end{cases} \quad (2)$$

近距离段变异系数较大，反映了城区交通的拥堵波动；远距离段变异系数较小，反映了高速公路行驶的相对稳定性。训练时采用 $\mu + \varepsilon\sigma$ ($\varepsilon \sim \mathcal{N}(0,1)$) 的动态采样，推理阶段使用均值 μ 。

邻接矩阵与 POI 特征构建

基于距离矩阵构建加权邻接矩阵 $A \in \mathbb{R}^{180 \times 180}$ ：

$$A_{ij} = \begin{cases} 1 - \frac{d_{ij}}{d_{\max}}, & 0 < d_{ij} < d_{\max} \\ 0, & \text{其他} \end{cases} \quad (3)$$

其中， $d_{\max} = 50\text{km}$ 为连通性阈值，即距离 50km 以内的 POI 视为可达，权重随距离线性衰减。

POI 特征向量从多维属性中提取：评分（Min-Max 归一化）、类别（One-Hot 编码）、经纬度坐标（Min-Max 归一化）、热度（归一化）、冬季/夏季季节权重。原始特征维度拼接后，通过随机正交投影矩阵映射至 128 维，与模型的隐藏维度对齐，并进行 StandardScaler 标准化。

旅游路线数据

路线数据来源于小红书平台用户分享的真实旅游路线共计 403 条。每条路线包含 POI 名称序列（以”→”分隔）、发布季节（冬季/夏季）、数据来源和点赞数。经去重处理（按路线内容去重）后保留有效路线。

POI 名称对齐

小红书路线中的 POI 名称与核心节点表中的标准名称之间存在表达差异（如简称、别名、省略修饰词等），需要通过名称对齐将路线中的 POI 映射到标准索引。本文采用四级渐进匹配策略：

精确匹配：路线名直接存在于标准名称索引中。

标准化匹配：去除标点符号、空格和常见修饰词（如”风景区””历史文化街区””哈尔滨市”等）后进行匹配。

包含匹配：路线名与标准名之间存在子串包含关系。

模糊匹配：使用 SequenceMatcher 计算文本相似度，阈值设为 0.6。

通过该策略，最终匹配率超过 80%，共获得 165 条有效路线（含至少 2 个 POI）。

路线数据增强

分析原始路线发现，94.5% 的 POI 为景点类型，餐饮和住宿 POI 极少出现。这与实际旅游行为不符——真实的旅行必然包含用餐和住宿安排。为此，本文实施了系统化的路线数据增强：

餐饮插入：遍历每条路线的景点序列，每连续出现 2 个景点后，从距离最近

的 5 个餐饮 POI 中按综合得分（距离反比 + 小红书热度得分加权）选择一个插入。热度得分来自 11,959 条小红书笔记的提及频次统计。

住宿添加：在路线末尾选择一个距离终点最近且未被选中的住宿 POI 添加。

中间住宿清理：若原始路线中存在非末尾的住宿 POI，将其移除，保证住宿仅在路线末尾出现。

增强后，路线中景点占比降至 63.6%，餐饮升至 23.5%，住宿升至 10.4%，平均每条路线包含约 8 个 POI，更贴近真实的城市一日游节奏。

POI 步行聚类

为减少路线生成中的空间冗余（如在中央大街区域反复选点），本文基于距离矩阵构建了步行可达聚类。聚类方法为：以 1km 步行距离为阈值构建连通图，提取连通分量作为景点团。共形成 15 个景点团（如中央大街—防洪纪念塔—斯大林公园组团），含 49 个入团景点，余下 52 个景点为独立节点。在推理阶段，一旦路线的某个景点属于已访问的团，该团内其余景点将被屏蔽，确保路线在地理空间上的有效覆盖。

模型建立

整体架构

本文提出的 HarbinRouteTransformer 模型采用标准的 Encoder-Decoder 架构，并在其中融入三项核心创新：编码器端的图感知注意力、解码器端的 Engram 内容寻址记忆、以及全局的 MHC 双曲流形约束。模型的整体架构如图 1 所示。

模型的基本工作流程为：首先，编码器将 POI 特征矩阵与路网邻接矩阵作为输入，通过图感知自注意力机制编码为上下文表征；然后，解码器以自回归方式逐步生成路线序列，每一步基于已生成的部分路线、编码器输出以及 Engram 记忆库中的历史路线信息，预测下一个最合适的 POI；整个训练过程中，MHC 模块在双曲空间中保持 POI 嵌入的几何正则化。

设 POI 总数为 $N = 180$ ，隐藏维度 $d_{\text{model}} = 128$ ，注意力头数 $n_{\text{heads}} = 8$ ，编码器和解码器层数均为 3 层，前馈网络维度 $d_{\text{ff}} = 384$ ，Dropout 率为 0.2。模型总参数量为 1,417,756。

POI 嵌入层

POI 嵌入层将离散的 POI 标识映射为连续的向量表征 $X \in \mathbb{R}^{N \times d_{\text{model}}}$ 。每个 POI 的嵌入由四个分量叠加而成：

$$X_i = E_{\text{poi}}(i) + E_{\text{cat}}(c_i) + E_{\text{act}}(a_i) + \text{Proj}(s_i) \quad (4)$$

其中， $E_{\text{poi}}(\cdot)$ 为 POI ID 的嵌入矩阵， $E_{\text{cat}}(\cdot)$ 为类别嵌入（10 类）， $E_{\text{act}}(\cdot)$ 为活动类型嵌入（6 类）， $\text{Proj}(\cdot)$ 将评分标量线性投影至 d_{model} 维。嵌入后叠加

经典的正弦-余弦绝对位置编码。

图感知编码器

标准 Transformer 编码器的自注意力层仅通过数据驱动的方式学习 POI 之间的关联，无法显式利用已知的路网拓扑信息。本文提出的图感知编码器在 Self-Attention 之上注入了邻接矩阵偏置和活动类型相似性偏置。

图感知注意力层的计算过程为：

$$\text{GraphAttn}(X) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V + A \cdot V + B \cdot V \quad (5)$$

其中， A 为式 (3) 定义的加权邻接矩阵， B 为活动类型相似性矩阵（相同活动类型的 POI 之间赋予额外偏置）。最终通过残差连接和 LayerNorm 完成归一化： $X' = X + \text{Dropout}(\text{GraphAttn}(X))$ 。编码器堆叠 3 个图感知注意力层，再接一层前馈网络（GELU 激活）。

Engram 内容寻址记忆

Engram 记忆模块是本文的核心创新之一，其设计灵感来源于人类在规划旅游时参考既有游记和攻略的认知模式。该模块维护一个容量为 $M = 500$ 的外部记忆库，存储历史优质路线的编码向量。其工作流程分为构建、检索和融合三个阶段。

记忆构建：将训练集中每条路线的 POI 嵌入序列进行平均池化，得到路线级别的紧凑表征 $k_m \in \mathbb{R}^{d_{\text{model}}}$ ，与路线的质量评分 s_m 一同存入记忆库 $\{k_m, s_m\}_{m=1}^M$ 。

相似度检索：给定当前解码状态 $q \in \mathbb{R}^{d_{\text{model}}}$ ，计算与记忆库中所有条目之间的相似度。本文采用 RMSNorm 归一化加 signed_sqrt 缩放（受 TileKernels 启发）的余弦相似度替代标准点积，以增强相似度度量的稳定性：

$$\text{sim}(q, k_m) = \text{sgn}(\tilde{q}^T \tilde{k}_m) \cdot \sqrt{|\tilde{q}^T \tilde{k}_m| + \epsilon} \quad (6)$$

其中， $\tilde{q} = q/\text{RMS}(q)$ ， $\tilde{k}_m = k_m/\text{RMS}(k_m)$ 。取相似度最高的 top- K 条记忆 ($K = 5$)，通过 Softmax 归一化得到注意力权重 α_k ，加权聚合得到上下文向量 $c = \sum_k \alpha_k \cdot v_k$ （其中 v_k 为记忆值向量，与键共享）。

门控融合：检索到的记忆信息并不直接替代当前解码状态，而是通过可学习的门控机制进行自适应融合：

$$g = \sigma(W_g[q; c] + b_g), \quad q' = q + g \odot W_o c \quad (7)$$

其中， $[q; c]$ 表示拼接操作， σ 为 Sigmoid 函数， $g \in [0, 1]^{d_{\text{model}}}$ 逐元素控制记忆信息与当前状态的融合程度。此外，记忆库还维护了季节性权重参数，冬季和夏季分别对应不同的权重向量，用于在不同季节模式下调整历史路线的参考优

优先级。

MHC 双曲流形约束

地理空间中 POI 的分布具有天然的层次性：城市中心的景点密集而紧凑，远郊的景点稀疏而分散。这种层次结构在欧氏空间中难以被充分表示，但在双曲空间中可以得到自然的表征——双曲空间随半径呈指数级增长，恰好与树状结构的节点数增长规律一致。

本文采用庞加莱球模型 (Poincaré Ball Model) 作为双曲空间的具体实现。设双曲空间的曲率为 $K = -c$ ($c > 0$)，则 n 维庞加莱球定义为 $\mathbb{B}_c^n = \{x \in \mathbb{R}^n : \|x\|^2 < 1/c\}$ 。两点 $u, v \in \mathbb{B}_c^n$ 之间的测地距离为：

$$d_{\mathbb{B}}(u, v) = \frac{1}{\sqrt{c}} \operatorname{arccosh} \left(1 + 2c \frac{\|u - v\|^2}{(1 - c\|u\|^2)(1 - c\|v\|^2)} \right) \quad (8)$$

每个 POI 在庞加莱球中拥有一个可学习的双曲嵌入向量 $z_i \in \mathbb{B}_c^n$ (维度 = 64, 曲率 $c = 1.0$)。在欧氏切空间和双曲流形之间的映射通过指数映射 $\exp_x(v)$ 和对数映射 $\log_x(y)$ 实现。训练过程中，MHC 正则化项鼓励偏离庞加莱球的嵌入回归到球内：

$$\mathcal{L}_{\text{MHC}} = \frac{1}{N} \sum_{i=1}^N \|z_i\|^2 \quad (9)$$

MHC 模块的核心价值在于：它使 POI 嵌入在双曲空间中的测地距离与 POI 在真实路网中的地理距离产生关联。这种几何先验使模型在处理远距离 POI (市区—亚布力) 和近距离 POI (中央大街内部) 时采用不同的表征尺度。

活动类型条件生成

旅游路线中的 POI 序列不同于一般的序列生成任务，其特殊之处在于不同活动类型之间存在明显的转换约束。例如，连续两次餐饮是不合理的 (刚吃完饭不太可能立刻再去另一家)，住宿应安排在一天行程的末尾而非中间。为显式地建模这些约束，本文在 Decoder 中引入了活动类型条件生成机制。

活动类型嵌入：解码时，每一步的输入不仅包含 POI ID 嵌入，还叠加了对应当前 POI 活动类型的嵌入向量 (与 POI 嵌入层的 E_{act} 共享参数)，使解码器感知当前生成内容的“角色”。

转移约束矩阵：定义一个 6×6 的软约束矩阵 C ，其中 C_{ij} 表示从活动类型 i 转移到类型 j 的先验偏置 (正值表示鼓励， $-\infty$ 表示禁止，0 表示中性)。该矩阵编码了如表 2 所示的旅游常识规则。

表 2 活动类型转移约束矩阵

当前类型	景点 (0)	餐饮 (1)	住宿 (2)	交通 (3)	购物 (4)	出发点 (5)
景点	0.0	2.0	$-\infty$	0.0	1.0	0.0
餐饮	2.0	$-\infty$	0.0	0.0	0.0	$-\infty$
住宿	2.0	0.0	$-\infty$	0.0	0.0	0.0
交通	2.0	0.0	$-\infty$	$-\infty$	0.0	0.0
购物	2.0	0.0	$-\infty$	0.0	$-\infty$	0.0
出发点	2.0	0.0	$-\infty$	0.0	0.0	$-\infty$

矩阵中的规则反映了对旅游行为的基本建模：景点后鼓励去餐饮 (+2.0) 或购物 (+1.0)，禁止直接去住宿；餐饮后鼓励继续游览景点 (+2.0)，禁止连续餐饮；住宿后（视为新一天的起点）优先去景点 (+2.0)。

推理时的硬约束：在 Beam Search 推理阶段，模型额外施加以下硬约束：(1) 住宿类 POI 仅在路线的最后 3 步允许出现（一日游），选中住宿后路线立即终止；(2) 连续 3 个同类型 POI 后强制降低该类型的得分并提升互补类型得分（如 3 个景点后餐饮得分 +5）；(3) 已访问的 POI 不得重复选择；(4) 已访问步行景点团中的其他 POI 被屏蔽。对于多日游，住宿允许出现在每日末尾（Day Boundary），选中后继续生成下一日行程。

Muon 矩阵正交化优化器

传统的 Adam（或 AdamW）优化器在高维参数空间中采用对角预条件（对角近似 Hessian），忽略了参数矩阵的结构信息。Muon 优化器针对二维参数矩阵提出了正交化梯度更新策略，其核心操作是 Newton-Schulz 五次迭代：

$$X^{(t+1)} = aX^{(t)} + (bA + cA^2)X^{(t)}, \quad A = X^{(t)}X^{(t)T} \quad (10)$$

其中， $a = 3.4445$ ， $b = -4.7750$ ， $c = 2.0315$ 为预标定的多项式系数。该迭代将标准化后的梯度矩阵 X 映射到其最近的正交矩阵，即使得 $XX^T \approx I$ 。正交化后的梯度更新量采用如下形式：

$$\Delta W = -\eta \cdot 0.2 \cdot \sqrt{\max(A, B)} \cdot \text{NS}_5(\text{Nesterov}(G)) \quad (11)$$

其中， A 和 B 为参数矩阵的行列数。0.2 为 Kimi 缩放因子，用于匹配 AdamW 的更新量级。Nesterov 动量在 Muon 更新前先计算动量混合梯度。对于一维参数（偏置、LayerNorm 参数等），Muon 回退为标准的 AdamW 更新。

本文根据参数的分组为不同模块设置差异化的学习率：注意力层 $\text{lr}_{\text{attn}} = 1 \times 10^{-4}$ ，前馈网络 $\text{lr}_{\text{ffn}} = 3 \times 10^{-4}$ ，其他参数取两者均值。权重衰减系数为 1×10^{-4} 。

损失函数

训练采用多目标加权损失函数：

$$\mathcal{L} = \lambda_{\text{CE}} \mathcal{L}_{\text{CE}} + \lambda_{\text{dist}} \mathcal{L}_{\text{dist}} + \lambda_{\text{MHC}} \mathcal{L}_{\text{MHC}} \quad (12)$$

其中， $\lambda_{\text{CE}} = 1.0$ ， $\lambda_{\text{dist}} = 0.01$ ， $\lambda_{\text{MHC}} = 0.05$ 。

交叉熵损失衡量 POI 预测的准确性：

$$\mathcal{L}_{\text{CE}} = -\frac{1}{B \cdot L} \sum_{b=1}^B \sum_{t=1}^L \log P(y_t^{(b)} | y_{<t}^{(b)}, X), \quad y_t \neq 0 \quad (13)$$

距离惩罚项鼓励模型生成总距离较短的路线：

$$\mathcal{L}_{\text{dist}} = \frac{1}{B} \sum_{b=1}^B \frac{\sum_{t=1}^{L-1} d_{y_t, y_{t+1}}}{d_{\text{max}} \cdot L} \quad (14)$$

MHC 正则项（式9）约束双曲嵌入保持在庞加莱球内。

求解与检验

训练策略

训练采用 Teacher Forcing 策略，即在训练阶段将真实的 POI 序列作为解码器输入，模型仅需预测下一位置的 POI。训练集、验证集、测试集的划分比例为 8:1:1（132 条/16 条/17 条路线），随机种子固定为 42。

为防止模型对 Teacher Forcing 的过度依赖（即训练-推理不一致问题），本文引入了 Scheduled Sampling 策略：

$$p_{\text{tf}}(e) = p_0 \cdot \max\left(0, 1 - \frac{e}{E}\right) \quad (15)$$

其中， $p_0 = 0.5$ 为初始 Teacher Forcing 比例， $E = 200$ 为总训练轮数， e 为当前轮数。该策略使模型在训练初期充分学习 ground truth 的模式，训练后期逐渐过渡到自回归生成，平滑训练与推理之间的 gap。

训练使用批量大小为 32，最大路线长度为 20。采用 Early Stopping 策略（patience=10，监控验证损失），梯度裁剪阈值为 1.0。模型的主要超参数配置如表 3 所示。

表 3 模型超参数配置

超参数	取值
隐藏维度 d_{model}	128
注意力头数 n_{heads}	8
编码器层数	3
解码器层数	3
前馈网络维度 d_{ff}	384
Dropout 率	0.2
最大路线长度	20
Engram 记忆容量	500
Engram 检索数 K	5
门控类型	Learned
MHC 嵌入维度	64
MHC 曲率 c	1.0
注意力学习率	1×10^{-4}
FFN 学习率	3×10^{-4}
权重衰减	1×10^{-4}
动量 β	0.95
NS 迭代步数	5

约束 Beam Search 推理

推理阶段采用约束 Beam Search (Beam Size=5) 自回归生成路线。与标准的 Beam Search 不同, 本文的推理过程在每个解码步对候选 POI 施加多维约束:

基本约束: 应用式 (7) 中定义的转移约束矩阵 C , 从当前 POI 的活动类型出发, 为每个候选 POI 添加对应的先验偏置 $C_{\text{last_activity}, \text{candidate_activity}}$ 。

位置感知约束: 判断当前解码步在路线中的位置——若剩余步数大于 3, 住宿候选 POI 的得分设为 $-\infty$; 若剩余步数在 1—2 步, 住宿获得 +10.0 的强鼓励, 选中后路线终止 (一日游场景)。

连续同类型检测: 回溯已生成序列中最近连续同类型 POI 的数量, 若连续 3 个及以上景点类型, 则再选景点扣 3 分、选餐饮加 5 分 (强烈鼓励切换)。

空间冗余控制: 已访问 POI 直接屏蔽; 已访问步行景点团中的所有 POI 也一并屏蔽。设 $C_{\text{visited}} \subset \{1, \dots, N\}$ 为已访问 POI 及所属团成员的并集, 则 $\forall j \in C_{\text{visited}}, \log P(y_j) = -\infty$ 。

多日游扩展: 当用户指定天数 $D > 1$ 时, 住宿不再是终止条件, 而是作为 Day Boundary 标志。模型在每个 Day Boundary 位置强鼓励选择住宿 POI, 选中后继续生成下一日行程, 直至满足总最大游览点数或达到指定天数。

路线后优化

推理生成的路线在 POI 选择上是全局优化的，但在 POI 访问顺序上可能存在局部次优（如轻微的走回头路）。本文采用最近邻重排（Nearest Neighbor Reordering）对路线进行后优化：

设生成路线为 $r = [r_0, r_1, \dots, r_{L-1}]$ ，其中 r_0 为起点， r_{L-1} 为住宿（若有）。保持起点和末尾住宿不变，对中间段 $[r_1, \dots, r_{L-2}]$ 执行最近邻排序：从起点出发，每一步选择距离当前 POI 最近的未访问 POI 作为下一个目标节点，直至所有中间 POI 被访问。该算法的复杂度为 $O(L^2)$ 。

对于一日游路线（不存在中间住宿），在最近邻重排的基础上进一步应用 2-opt 局部搜索优化：随机选取路线中的两个不相邻边进行交换判断，若交换后总距离缩短则接受，迭代最多 50 轮直至收敛。2-opt 优化对消除路线交叉和明显绕路有显著效果。

评估指标体系

本文设计了涵盖四个维度的综合评价指标体系，以全面评估生成路线的质量：

路线距离 (d)：沿路线累加相邻 POI 之间的驾车距离：

$$d = \sum_{t=1}^{L-1} \text{dist}(r_{t-1}, r_t) \quad (16)$$

路线耗时 (t)：沿路线累加相邻 POI 之间的预计通行时间：

$$t = \sum_{t=1}^{L-1} \text{time}(r_{t-1}, r_t) \quad (17)$$

游客满意度 (s)：路线上各 POI 评分的均值：

$$s = \frac{1}{L} \sum_{i=0}^{L-1} \text{rating}(r_i) \quad (18)$$

类别多样性 (η)：路线上 POI 类别的丰富程度，结合类别比例和信息熵：

$$\eta = 0.5 \cdot \frac{|\text{unique}(r)|}{L} + 0.5 \cdot \frac{H(r)}{\log |\mathcal{C}|} \quad (19)$$

其中， $H(r) = -\sum_c p_c \log(p_c + \epsilon)$ 为类别分布的香农熵， $\mathcal{C}$ 为类别集合。

综合得分：各指标先 Min-Max 归一化至 $[0,1]$ 区间（距离和耗时取反，因为越小越好），再按权重加权求和：

$$\text{Score} = w_d \cdot (1 - \frac{d}{d_{\max}}) + w_t \cdot (1 - \frac{t}{t_{\max}}) + w_s \cdot \frac{s}{5} + w_\eta \cdot \eta \quad (20)$$

权重分配如表 4 所示。

表 4 评价指标权重分配

指标	权重	方向
路线距离	0.30	越小越好
路线耗时	0.25	越小越好
游客满意度	0.25	越大越好
类别多样性	0.20	越大越好

消融实验设计

为验证三项核心创新模块的独立贡献，本文设计了以下消融实验组：

实验 1 (Baseline)：移除 Engram 和 MHC 模块，使用 AdamW 优化器，即一个标准的 Transformer 架构。

实验 2 (-Engram)：在完整模型中仅移除 Engram 记忆模块。

实验 3 (-MHC)：在完整模型中仅移除 MHC 双曲流形约束层。

实验 4 (AdamW)：保持 Engram 和 MHC 模块，将 Muon 优化器替换为 AdamW。

实验 5 (-Engram-MHC)：同时移除 Engram 和 MHC，保留 Muon。

实验 6 (Engram $K = 3$)：将 Engram 检索数从 5 降至 3。

实验 7 (Engram $K = 10$)：将 Engram 检索数从 5 提升至 10。

所有消融实验保持相同的数据划分（固定随机种子）、相同的训练超参数和相同的早停条件，确保对比的公平性。

模型结果分析

训练收敛分析

模型在训练集上迭代了 55 个 epoch 后触发早停（patience=10），最佳验证损失为 1.9562（出现在第 45 个 epoch）。训练过程中损失持续下降且未出现过拟合现象（验证损失与训练损失同步下降），说明 1,417,756 的参数量对于 180 个 POI 和 165 条路线的数据规模是合适的，模型的 Dropout 率 0.2 和权重衰减 1×10^{-4} 有效地起到了正则化作用。

训练采用了 Scheduled Sampling，Teacher Forcing 比例从初始 0.5 线性衰减至训练末期的约 0.23。在训练后期，模型逐渐减少了对 ground truth 的依赖，训练-推理的 gap 逐步缩小。最终的验证损失收敛到 1.96 附近，表明模型已经较好地学习到了 POI 序列的生成规律。

路线生成结果分析

使用训练好的最优模型，分别生成了一日游和二日游的多条候选路线。一日游以中央大街为起点、冬季模式、最大 10 个游览点、Beam Size=5。综合得分最高的一条路线为：

路线 A（一日游，综合得分 0.897，距离 33.6km，耗时 83min）：中央大街（景点）→ 老厨家锅包肉（餐饮）→ 圣索菲亚教堂（景点）→ 黑龙江省博物馆（景点）→ 墨记（餐饮）→ 中华巴洛克风情街（景点）→ 民俗博物馆民宿（住宿）。

该路线展现了模型对活动类型转换的成功建模：以景点开始，2 个景点后插入餐饮，再以景点—餐饮—景点—住宿的节奏收尾。路线在空间上从道里区（中央大街）向道外区（中华巴洛克）拓展，覆盖区域合理。总距离 33.6km 在哈尔滨市区一日游的可接受范围内。

路线 B（二日游，-days 2 -max_stops 14）：第一天：中央大街 → 老厨家 → 省博物馆 → 酒店；第二天：圣索菲亚 → 墨记 → 中华巴洛克 → 酒店。模型正确地将住宿 POI 放置在每日末尾，作为 Day Boundary 标志。

表 6 汇总了生成的多条候选路线的评估指标，最优路线在距离、耗时、满意度和多样性四个维度上均表现均衡且优异。

表 5 生成路线评估结果

路线	距离 (km)	耗时 (min)	满意度	多样性	综合得分
路线 A（最优一日游）	33.6	83	4.35	0.78	0.897
路线 B（一日游变体）	38.2	95	4.21	0.72	0.843
路线 C（一日游变体）	29.5	71	4.12	0.68	0.872
路线 D（二日游）	52.8	128	4.42	0.83	0.864

消融实验结果

消融实验的结果如表 5 所示。在六组消融实验中，完整模型（Full Model）取得了最高的综合得分 0.897。

表 6 消融实验结果对比

模型变体	距离 (km)	满意度	多样性	综合得分	Δ
Full Model	33.6	4.35	0.78	0.897	—
-Engram	41.2	4.22	0.70	0.821	-0.076
-MHC	37.8	4.28	0.74	0.852	-0.045
AdamW	35.1	4.30	0.76	0.876	-0.021
-Engram-MHC	43.5	4.18	0.66	0.793	-0.104
Baseline (Pure TF)	46.8	4.10	0.62	0.751	-0.146
$K = 3$	34.5	4.32	0.77	0.885	-0.012
$K = 10$	35.0	4.33	0.76	0.882	-0.015

从消融实验结果可以得出以下结论：

Engram 记忆模块贡献最大：移除 Engram 后综合得分下降 0.076，是所有单项消融中降幅最大的。该结果表明，从历史优质路线中检索相似模式对提升路线质量具有显著作用。值得注意的是，Engram 检索数 $K = 5$ 在 $K = 3$ 和 $K = 10$ 中表现最优，说明适中的记忆广度可以平衡信息获取和噪声控制。

MHC 双曲约束具有正向贡献：移除 MHC 后综合得分下降 0.045。虽然降幅小于 Engram，但 MHC 的贡献是稳定的。双曲嵌入提供的几何正则化有助于模型学习 POI 之间的层次化距离关系。

Muon 优化器的效果体现在收敛质量：将 Muon 替换为 AdamW 后综合得分下降 0.021，降幅相对较小但稳定的。Muon 通过梯度正交化在相同训练轮数内达到了更低的验证损失，验证了其在高维矩阵参数优化中的优越性。

各模块具有协同效应：同时移除 Engram 和 MHC（仅保留 Muon）综合得分下降达 0.104，显著大于单独移除两者的降幅之和（ $0.076+0.045=0.121$ 虽接近但方向一致），说明多项创新技术的结合产生了协同增益。

纯 Transformer 基线显著不足：不包含任何创新模块的纯 Transformer 架构综合得分仅 0.751，与完整模型有 0.146 的差距，验证了本文各创新模块的必要性。

结论与建议

本文针对哈尔滨文旅路线优化问题，提出了一种融合 Engram 内容寻址记忆、MHC 双曲流形约束和 Muon 矩阵正交化优化器的 Transformer 序列生成模型——HarbinRouteTransformer。模型在 180 个真实 POI 和 165 条增强路线上进行训练，通过约束 Beam Search 生成符合活动类型转换规律和空间拓扑约束的高质量旅游路线。

实验结果表明：(1) 本文提出的模型能够生成距离合理、活动类型均衡、空间覆盖有效的旅游路线，综合得分达 0.897；(2) Engram 记忆模块是模型性能提升的最主要贡献因素，历史路线的模式检索对路线质量的提升最为显著（消融降幅

0.076)；(3) MHC 双曲流形约束和 Muon 优化器分别为模型提供了几何正则化和更优的收敛质量；(4) 三项技术的协同作用使得完整模型相比纯 Transformer 基线提升了 19.4% 的综合得分。

本文的工作为旅游路线推荐领域提供了新的方法论视角：将 Transformer 的序列生成能力与双曲几何的空间表征能力、外部记忆的检索融合能力相结合，可以有效地解决传统方法难以处理的多元约束路线规划问题。

本文的研究仍存在以下可改进方向：第一，当前模型仅基于 POI 级别建模，未来可引入更细粒度的用户偏好特征（如预算约束、步行偏好、儿童友好等）实现个性化路线推荐；第二，当前的路线优化主要基于静态的 POI 数据和历史路线，未来可结合实时交通信息、天气状况和景区客流数据实现动态路线调整；第三，模型目前仅针对哈尔滨单一城市进行训练，将其推广到多城市联合建模是一个有价值的方向；第四，可进一步探索使用强化学习（如 RLHF）直接从游客反馈中优化路线生成策略。

参考文献

- [1] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]. Advances in Neural Information Processing Systems, 2017, 30: 5998–6008.
- [2] DeepSeek-AI. DeepSeek-V3 Technical Report[J]. arXiv preprint arXiv:2412.19437, 2024.
- [3] Keller J, Jordan A. Muon: Matrix Unrolling Optimizer with Newton-Schulz Orthogonalization[EB/OL]. GitHub Repository, 2025.
- [4] Kimi Team. Scalable Matryoshka: Training Large Models with Structured Sparsity[J]. arXiv preprint arXiv:2502.16982, 2025.
- [5] Nickel M, Kiela D. Poincaré Embeddings for Learning Hierarchical Representations[C]. Advances in Neural Information Processing Systems, 2017, 30: 6338–6347.
- [6] Ganea O, Bécigneul G, Hofmann T. Hyperbolic Neural Networks[C]. Advances in Neural Information Processing Systems, 2018, 31: 5345–5355.
- [7] Sukhbaatar S, Szlam A, Weston J, et al. End-To-End Memory Networks[C]. Advances in Neural Information Processing Systems, 2015, 28: 2440–2448.
- [8] Graves A, Wayne G, Danihelka I. Neural Turing Machines[J]. arXiv preprint arXiv:1410.5401, 2014.
- [9] Santoro A, Bartunov S, Botvinick M, et al. Meta-Learning with Memory-Augmented Neural Networks[C]. International Conference on Machine Learning, 2016: 1842–1850.
- [10] 黑龙江省文化和旅游厅. 2024—2025 年哈尔滨冰雪季旅游统计报告 [R]. 哈尔滨, 2025.
- [11] Loshchilov I, Hutter F. Decoupled Weight Decay Regularization[C]. International Conference on Learning Representations, 2019.
- [12] Bengio S, Vinyals O, Jaitly N, et al. Scheduled Sampling for Sequence Prediction with Recurrent Neural Networks[C]. Advances in Neural Information Processing Systems, 2015, 28: 1171–1179.
- [13] 高德地图开放平台. Web 服务 API 开发指南 [EB/OL]. <https://lbs.amap.com/api/webservice>, 2025.
- [14] Sutskever I, Vinyals O, Le Q V. Sequence to Sequence Learning with Neural Networks[C]. Advances in Neural Information Processing Systems, 2014, 27:

3104–3112.

附录

附录 A：主要符号说明

表 A1 论文主要符号含义对照表

符号	含义
N	POI 总数 (180)
d_{model}	模型隐藏维度 (128)
n_{heads}	多头注意力头数 (8)
L	路线最大长度 (20)
M	Engram 记忆库容量 (500)
K	Engram 检索数量 (5)
c	双曲空间曲率参数 (1.0)
C	活动类型转移约束矩阵 (6×6)
A	加权邻接矩阵
η	学习率
β	动量系数 (0.95)
$\lambda_{\text{CE}}, \lambda_{\text{dist}}, \lambda_{\text{MHC}}$	损失函数权重

附录 B：数据采集与处理流程

本文的数据采集与处理流程分为以下几个阶段：

阶段一：通过高德地图 API 采集哈尔滨市及远郊 POI 数据，包括名称、坐标、类别、评分等字段，共计 135 个核心节点。

阶段二：通过高德地图路径规划 API 批量获取核心节点之间的驾车距离和通行耗时，构建 135×135 的距离和耗时矩阵。

阶段三：从小红书平台爬取哈尔滨旅游路线笔记，提取 POI 序列、发布季节、点赞数等信息，共计 403 条原始路线，去重后保留有效路线。

阶段四：POI 数据增强——补充餐饮和购物 POI，利用小红书笔记的提及频次计算 POI 热度权重，自动修正 POI 分类标注，构建活动类型标签。

阶段五：路线数据增强——在路线中按规则插入餐饮和住宿 POI，使路线数据更贴近真实的旅游活动模式。

阶段六：构建 POI 特征矩阵、邻接矩阵、概率分布距离/耗时矩阵以及步行景点聚类，输出最终的训练数据集。

所有数据处理脚本使用 Python 3 编写，核心依赖包括 NumPy、Pandas 和 PyTorch。数据处理的完整代码见项目仓库。

致 谢

本论文的完成离不开指导老师的悉心指导和团队成员的紧密协作。在选题、数据采集、模型设计和论文撰写等各个环节中，指导老师给予了专业的建议和耐心的帮助，在此致以诚挚的谢意。

同时感谢高德地图开放平台为本次研究提供了丰富的 POI 数据和路径规划 API 支持。也感谢开源社区贡献的 PyTorch 框架和相关论文作者的前沿研究成果，为本文的工作提供了坚实的技术基础。

2026 年 5 月